AIoT · HW2 · MULTIPLE LINEAR REGRESSION

多元線性回歸分析：洪水機率與學生成績預測

以 CRISP-DM 流程，對兩個 Kaggle 資料集完成特徵選擇、模型評估與信賴區間／預測區間分析

姓名	邱勇嘉
學號	5115056022
主程式	`5115056022_hw2.ipynb`
GitHub	github.com/hobartXIII/HW2-Multiple-Linear-regression
互動網頁	hobartxiii.github.io/HW2-Multiple-Linear-regression
Kaggle 成績	Playground S4E5：Public R^2 0.84458 / Private R^2 0.84426（換算約 1,850 / 2,794 名）

一、研究脈絡與資料集來源

本作業要以「原始特徵數 10–20 個」的 Kaggle 公開資料集練習多元線性回歸。為了同時呈現兩種典型情境，選擇兩個性質互補的資料集：題目 A 全為數值特徵、樣本極多，可專注於模型與區間估計；題目 B 數值與類別混合、含缺失值，需完整的前處理。

題目	資料集與來源	筆數	特徵	目標
A	Regression with a Flood Prediction Dataset（Kaggle Playground Series S4E5） kaggle.com/competitions/playground-series-s4e5 檔案下載自 naiyakhalid/flood-prediction-dataset（CC0）	1,117,957	20（數值）	`FloodProbability`（0–1）
B	Student Performance Factors kaggle.com/datasets/lainguyn123/student-performance-factors（CC0）	6,607	19（6 數值、13 類別）	`Exam_Score`

資料集篩選過程：原先考慮的 50,000 筆版本 `flood.csv`，以 OLS 檢查時測試集 $R^2 = 1.000$、RMSE = 0，代表目標值是 20 個特徵的精確線性組合，無法做不確定性分析，因此改用含雜訊的競賽版 `train.csv`。另檢查了 Life Expectancy (WHO)（缺失 2,563 格、R^2 0.57）與 Seoul Bike Sharing（R^2 0.53，非線性強），最後選定上述兩者。兩個資料集都是合成資料，結論僅用於方法練習，不代表真實世界的效果大小。

二、CRISP-DM 分析流程：題目 A 洪水機率

1. Business Understanding

依季風強度、都市化、排水系統、堤防品質等 20 項指標（0–18 的評分）預測地區洪水機率，讓防災單位排序高風險地區、分配改善預算。競賽評分指標為 R^2，因此以測試集 R^2 與 RMSE 為主要指標，並以預測區間說明

單筆預測的不確定性。

2. Data Understanding

- 無缺失值、無重複列；目標值近似常態，90% 落在 0.42–0.59。
- 每個特徵與目標的相關係數都在 0.178–0.190 之間，沒有主導特徵；特徵之間幾乎不相關（$|r| < 0.02$），共線性風險低。

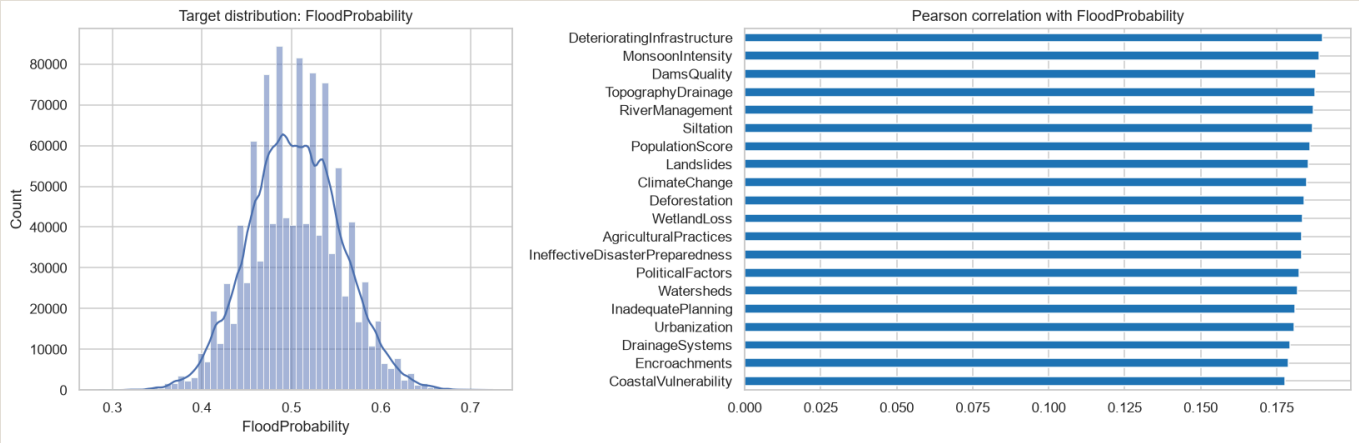


圖 A-1　目標分布與各特徵的相關係數

3. Data Preparation

移除流水號 `id`；80/20 切分（`random_state=42`），之後所有特徵選擇、標準化與超參數調整只用訓練集，避免資料洩漏。特徵選擇在訓練集中抽樣 60,000 筆進行（加速），最終模型使用完整訓練集（894,365 筆）。

4. Modeling：特徵選擇與模型比較

比較 5 種特徵選擇方法：SelectKBest（F 檢定）、RFE、Sequential Forward Selection、Lasso path、Permutation importance，計算每個 k 的 5-fold CV RMSE，選擇規則為「CV RMSE 在最佳值 0.5% 以內的最少特徵」。

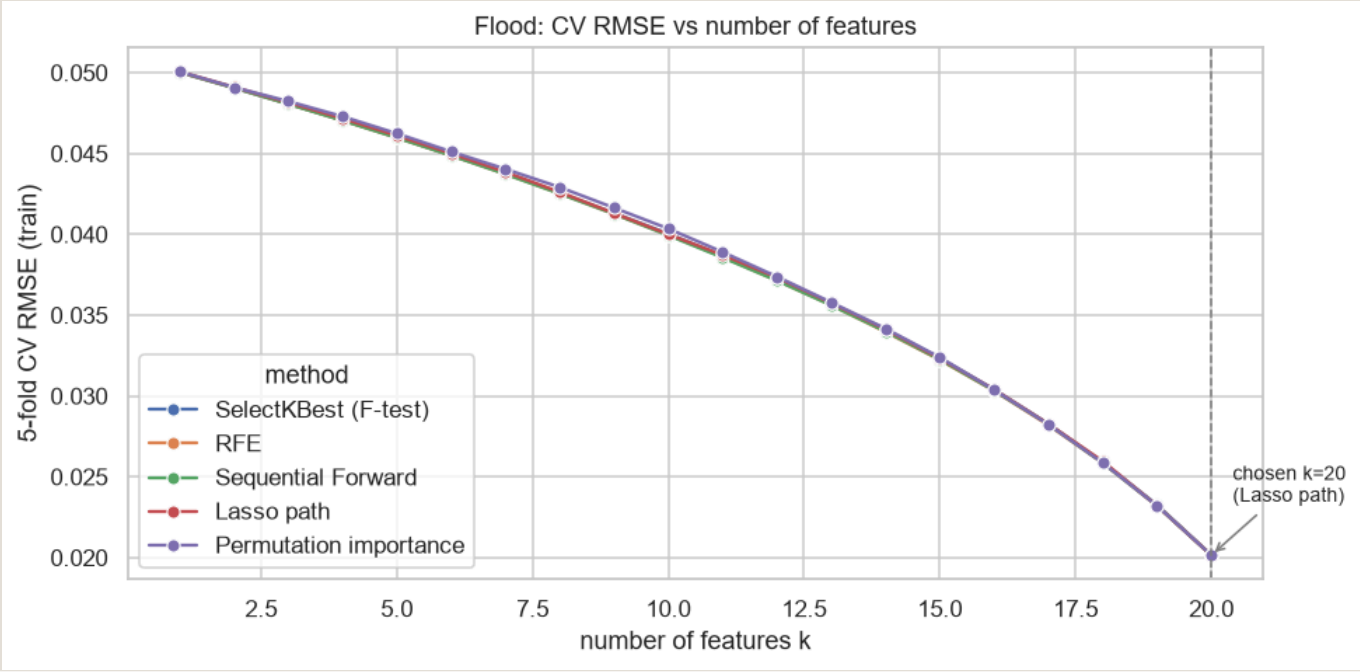


圖 A-2　特徵數 k 與 CV RMSE：五種方法到 k = 20 都持續下降（k = 19→20 仍由 0.0232 降到 0.0202）

結果是 **k = 20，全部保留**：每個特徵貢獻相同的訊號，刪掉任何一個都會讓誤差明顯上升，此處特徵選擇的價值在於「證明不能刪」。OLS、RidgeCV、LassoCV 的測試集表現完全相同（RMSE 0.02008、R^2 0.84488），因特徵互不相關，正則化沒有幫助。

係數的發現：20 個係數全部落在 0.0056–0.0057、信賴區間彼此重疊，截距 −0.0533。模型實際上是 `FloodProbability ≈ 0.00565 × (20 項評分總和) − 0.053`，各因素同等重要。

5. Evaluation

指標（測試集 223,592 筆）	MAE	MSE	RMSE	R^2	Adj. R^2	95% PI 覆蓋率
OLS（20 特徵）	0.01579	0.00040	0.02008	0.84488	0.84486	94.6%

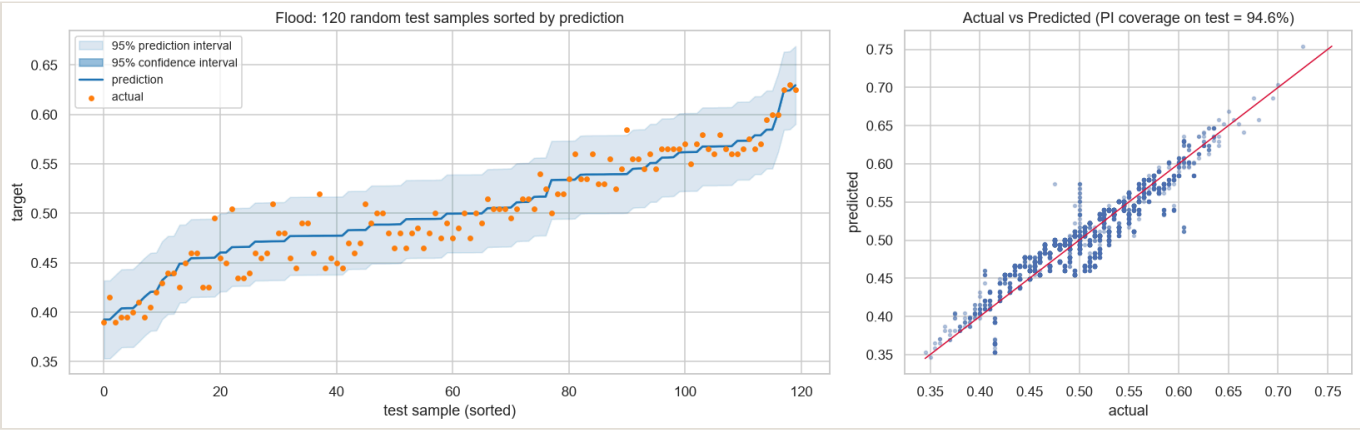


圖 A-3　預測圖：120 筆測試樣本依預測值排序，深色帶為 95% 信賴區間、淺色帶為 95% 預測區間；右圖為實際值對預測值

預測區間的實際覆蓋率 94.6%，接近名目 95%，代表區間寬度估計合理；信賴區間因樣本數大而窄到幾乎看不見。

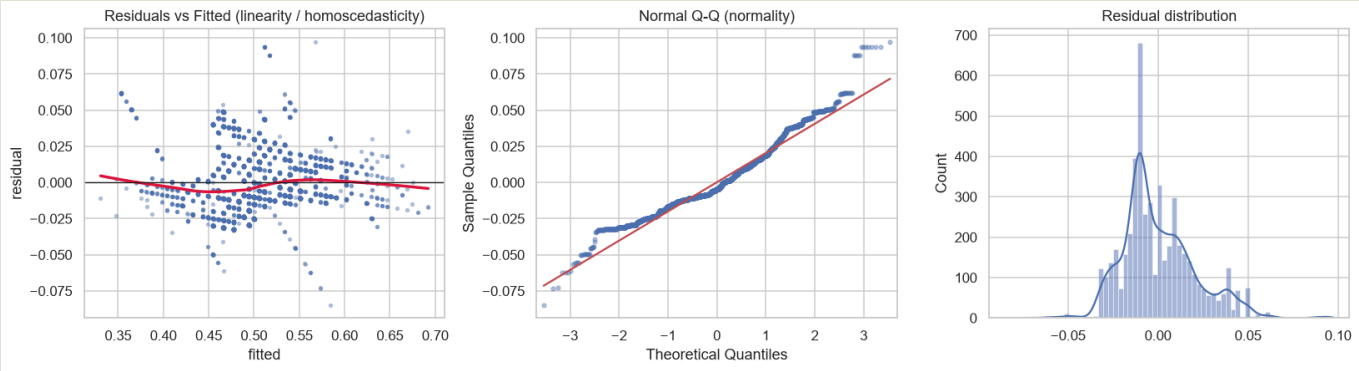


圖 A-4　殘差診斷：殘差 vs 配適值、Q-Q 圖、殘差分布

假設	檢查	數值	判斷
獨立性	Durbin-Watson	2.000	僅供參考：資料為隨機切分的橫斷面資料，列的順序沒有時間意義，DW 必然接近 2；獨立性由抽樣方式保證
同質變異	Breusch-Pagan p	≈ 0	不通過（近 90 萬筆時微小偏差也顯著）
常態性	Jarque-Bera p	≈ 0	不通過；Q-Q 圖兩端偏離
無共線性	最大 VIF	1.004	通過
線性	殘差圖 LOWESS	—	輕微 S 形，存在線性模型未捕捉的非線性

Kaggle 提交結果與名次

以全部 1,117,957 筆重新估計後，對 Kaggle 測試集（745,305 筆）預測並提交（late submission）：**Public R^2 0.84458、Private R^2 0.84426**，與本機測試集 R^2 0.845 幾乎相同，證實評估方式可信。以分數對照 Public 排行榜（2,794 隊），換算名次約為 **第 1,850 名**。

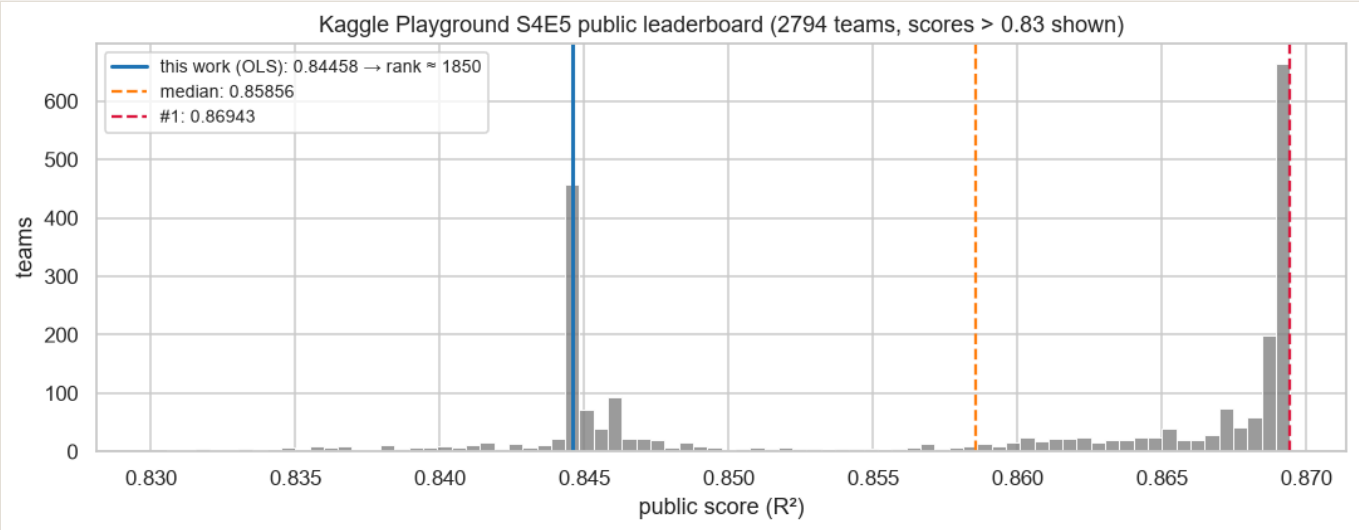


圖 A-5　Public 排行榜分數分布：本作業分數（藍線）位於約 450 隊聚集的 0.8446 一群；另約 660 隊聚集在 0.869

6. Deployment

模型（前處理器＋選定特徵＋OLS）以 joblib 存檔，`predict_with_interval()` 可對新資料輸出預測值與 95% CI／PI；同一流程也實作於互動網頁（第四節）。

三、CRISP-DM 分析流程：題目 B 學生考試成績

1. Business Understanding

依讀書時數、出席率、家長參與、家庭收入、師資品質等 19 項因素預測期末考成績，讓學校提早找出可能表現不佳的學生，並了解哪些「可改變的因素」影響最大。以 RMSE（單位為分數，易解釋）與 R^2 為指標，同時重視係數的可解釋性。

2. Data Understanding

- 6,607 筆；`Teacher_Quality`、`Parental_Education_Level`、`Distance_from_Home` 共 235 格缺失。
- `Attendance`（r = 0.58）與 `Hours_Studied`（r = 0.45）是最強的數值因素；`Sleep_Hours`、`Physical_Activity` 幾乎無關。
- 類別特徵中 `Access_to_Resources`、`Parental_Involvement` 的高低組差距明顯，`Gender`、`School_Type` 幾乎沒有差異。
- 目標 90% 落在 62–73 分，右尾有少數 80–101 分的離群值；有 1 筆 101 分超過滿分，因只有 1 筆而保留並註明。

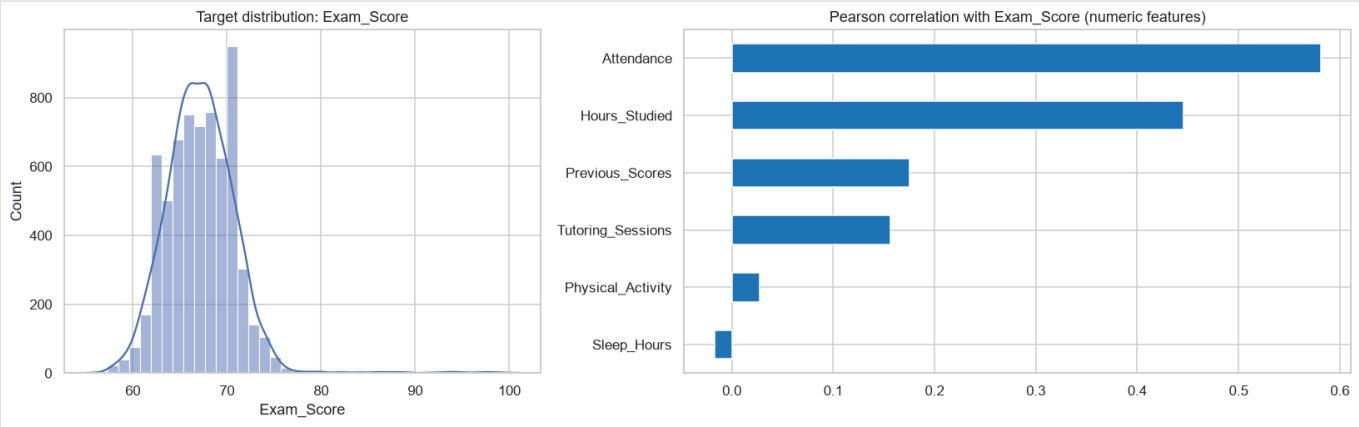


圖 B-1　目標分布與數值特徵的相關係數

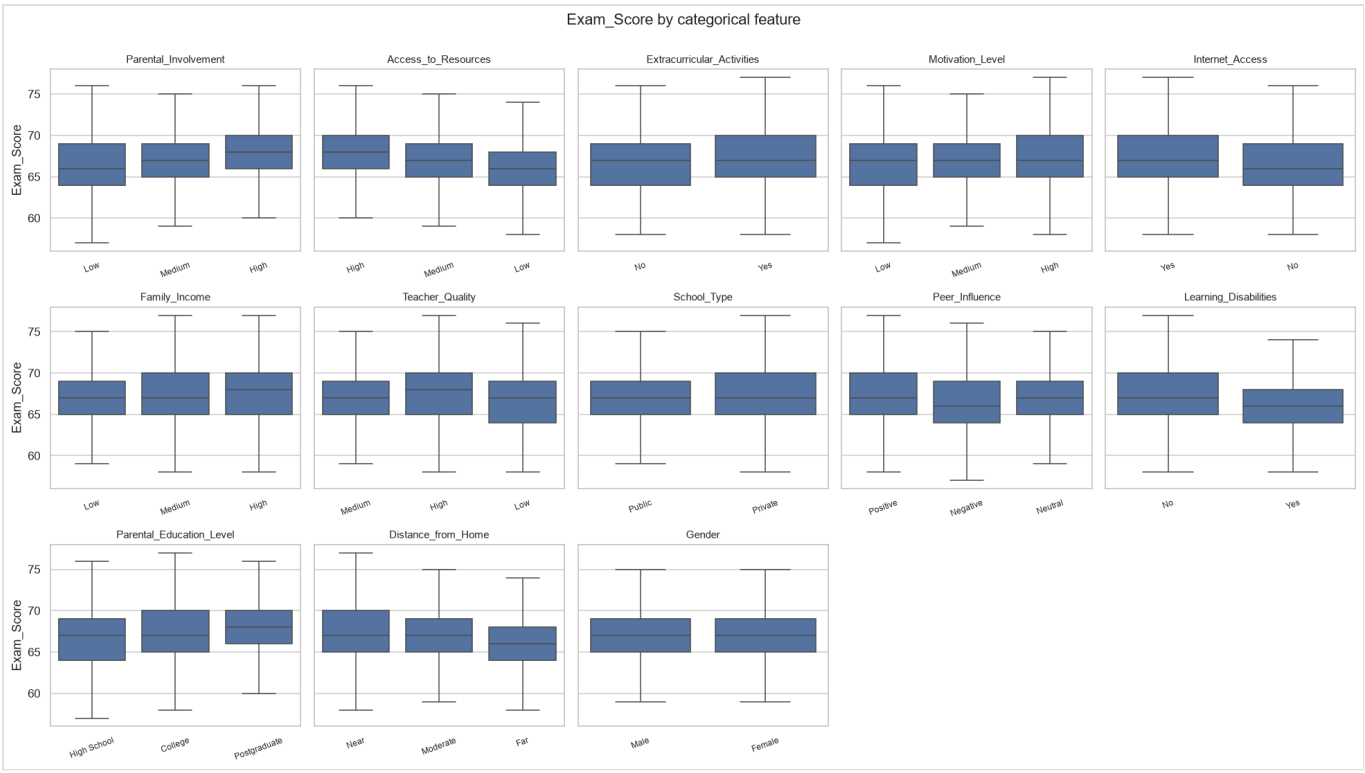


圖 B-2　各類別特徵下的成績分布

3. Data Preparation

80/20 切分後，只用訓練集計算補值（數值：中位數、類別：眾數）與類別水準；類別欄做 one-hot 編碼並刪除第一個類別（避開虛擬變數陷阱），19 個原始特徵展開為 27 個欄位。

4. Modeling：特徵選擇與模型比較

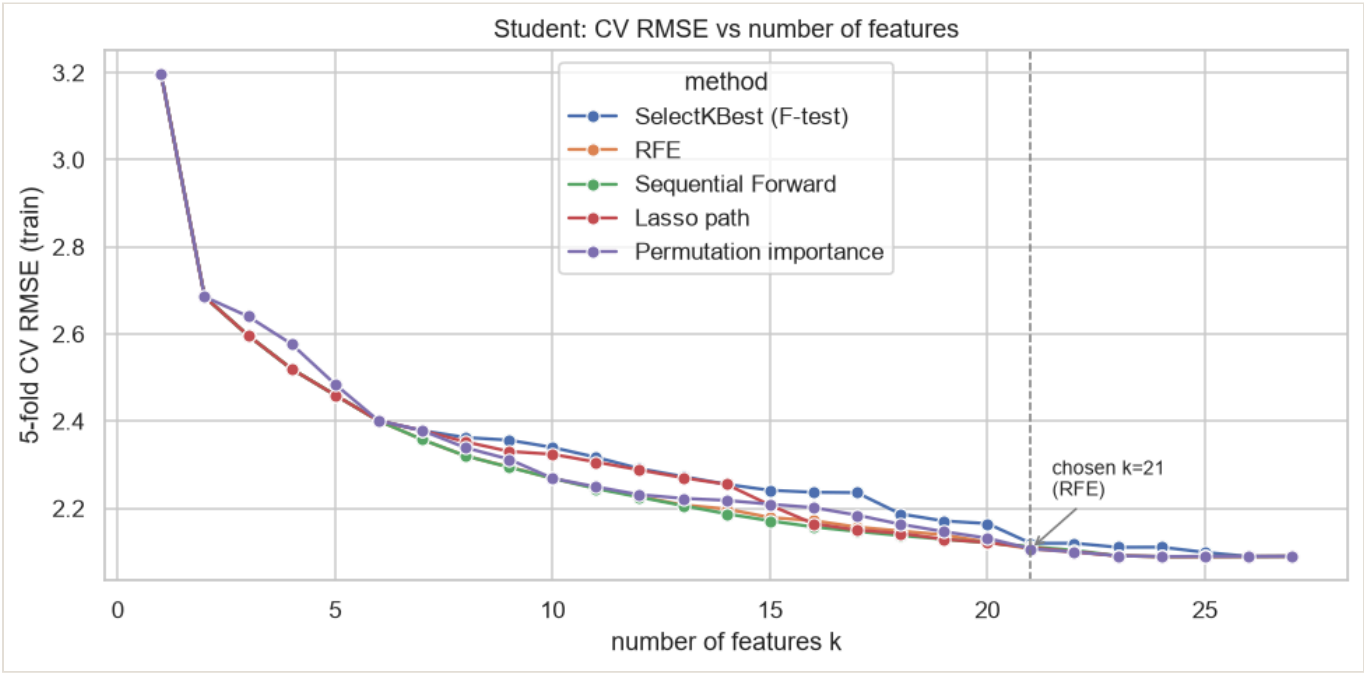


圖 B-3　特徵數 k 與 CV RMSE：前 6 個特徵加入後快速下降，之後趨平；k = 7–20 間多變量方法（Forward、RFE）優於 SelectKBest

5 種方法的前 6 名幾乎一致（出席率、讀書時數、前次成績、輔導次數、資源取得、家長參與）。以「CV RMSE 在最佳值 1% 以內的最少特徵」選出 RFE 的 **k = 21**，刪除 `Gender`、`School_Type`、`Sleep_Hours`、

`Physical_Activity` 與兩個效應較小的類別水準。

模型（測試集 1,322 筆）	k	MAE	RMSE	R^2	Adj. R^2	CV RMSE
OLS（全部特徵）	27	0.452	1.804	0.770	0.765	2.090
OLS（RFE 選出）	21	0.543	1.825	0.764	0.761	2.107
RidgeCV	27	0.452	1.804	0.770	0.765	2.090
LassoCV	27	0.452	1.804	0.770	0.765	2.090

精簡的代價：RMSE 與 R^2 相近，但 MAE 由 0.452 升到 0.543（約 +20%），因為被刪掉的兩個類別水準其實有小而真實的效應——刪掉一個虛擬變數等於把該水準併入基準類別。重視準確度可用全特徵模型，重視精簡與解釋則 k = 21 的損失很小。Ridge／Lasso 沒有更好，表示誤差不是來自過擬合。

方法限制：

- **CV 曲線略為樂觀：**SelectKBest、RFE 等排序是用整個訓練集算出後，再計算 5-fold CV RMSE，驗證折的資料間接參與了排序。改成在每一折內重新排序後重算，兩題的 CV 曲線最多相差約 1–2%，選出的 k 幾乎不變，測試集 RMSE 差異 ≤ 0.003。測試集從未參與特徵選擇，所以測試集指標不受影響。
- **係數區間是條件區間：**係數的信賴區間是在「特徵已選定」條件下的 OLS 區間，沒有計入特徵選擇本身的不確定性，可能略窄。題目 A 保留全部 20 個特徵，不受此影響。

主要係數（原始單位）：出席率每多 1 個百分點 +0.199 分；每週讀書每多 1 小時 +0.294 分；每多一次輔導 +0.511 分；資源取得「低」比「高」少 2.11 分；家長參與「低」比「高」少 2.00 分（p 值皆 < 0.0001）。

5. Evaluation

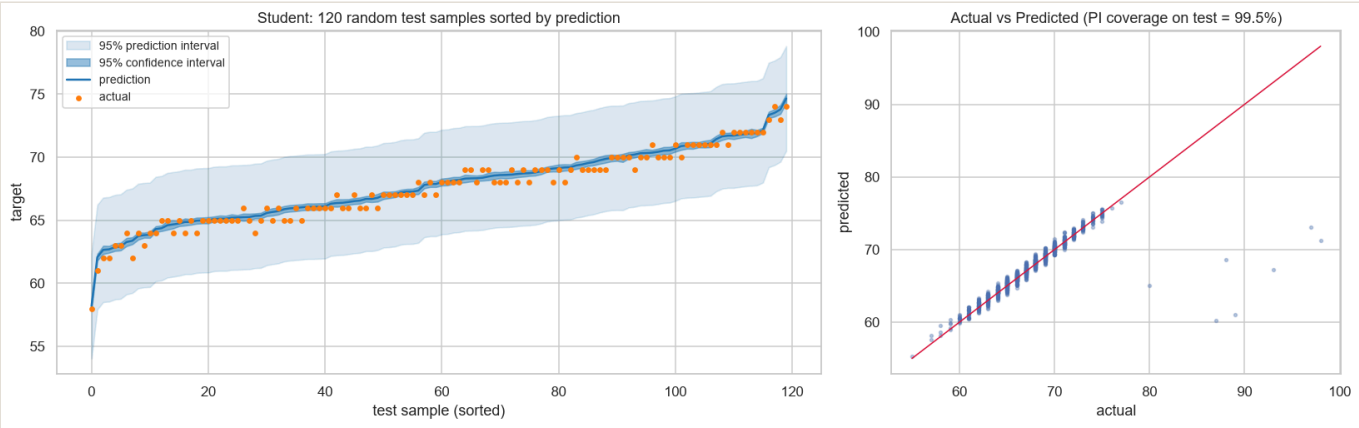


圖 B-4　預測圖（95% 信賴區間與預測區間）與實際值對預測值：少數學生實際 80–100 分、模型只預測 60–73 分

- **誤差幾乎全來自離群值：**98% 的測試殘差落在 ±1.3 分以內，|殘差| > 5 分的只有 0.5%。一般學生的分數幾乎就是各因素的線性加總，R^2 停在約 0.77 主要是這群離群值造成。
- **預測區間過寬：**覆蓋率 99.5% 高於名目 95%。OLS 的 PI 假設殘差常態，離群值把殘差標準差撐大到約 1.8，對一般學生而言 PI（約 ±4 分）過於保守。

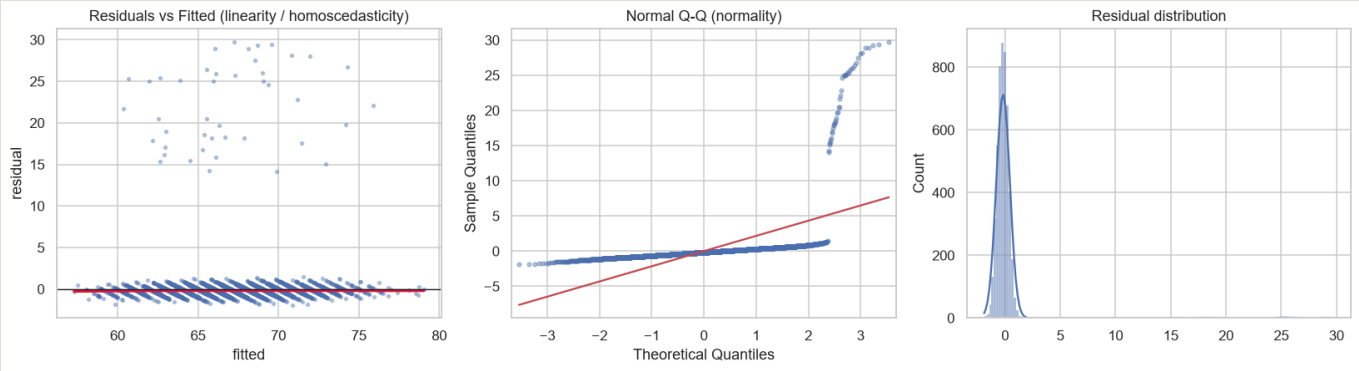


圖 B-5　殘差診斷：Q-Q 圖右上翹，為高分離群值造成的長右尾

假設	檢查	數值	判斷
獨立性	Durbin-Watson	1.949	僅供參考（理由同題目 A）
同質變異	Breusch-Pagan p	0.853	通過
常態性	Jarque-Bera p	≈ 0	不通過（長右尾）
無共線性	最大 VIF	1.86	通過

6. Deployment

模型存檔；對一位新學生（讀書 25 小時、出席 90%、家長參與高等）預測 74.01 分，95% CI 73.79–74.24、95% PI 69.87–78.15。CI 是「同條件學生的平均成績」範圍，PI 是「這一位學生」的範圍，所以 PI 寬得多。

四、加分功能：互動式網頁

網址：hobartxiii.github.io/HW2-Multiple-Linear-regression。純前端靜態網站（Tailwind CSS、Flowbite、ApexCharts、PapaParse），回歸運算全部在瀏覽器中以 JavaScript 完成，部署於 GitHub Pages。

- **下拉選單切換兩個題目**（加分 1）：側邊欄頂部切換題目 A／B，自動載入對應資料與預設目標。
- **輸入任意資料集網址**（加分 2）：貼上 CSV 網址（例如 50_Startups.csv）或拖曳上傳；自動判斷數值／類別欄、排除 ID 與高基數欄、one-hot 編碼與補值，再完成同樣的特徵選擇、OLS、CI／PI 與假設檢查。以 50_Startups 為例，自動選出 R&D Spend 與 Marketing Spend（k = 2），測試 R^2 0.946。
- **正確性驗證：**以相同切分與編碼和 Python statsmodels 比對 4 個案例，係數、標準誤、p 值、CI／PI、R^2、Durbin-Watson、Jarque-Bera、Breusch-Pagan、VIF 的最大相對誤差約 2×10^{-12}。

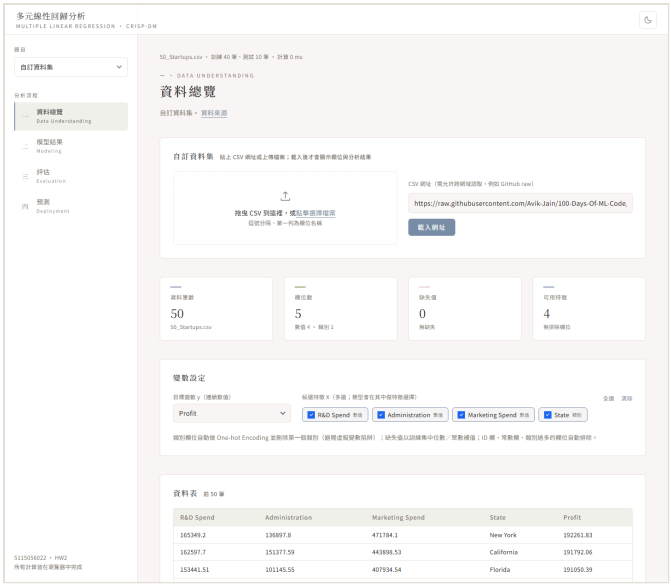


圖 W-1　輸入任意網址（50_Startups）後的資料總覽

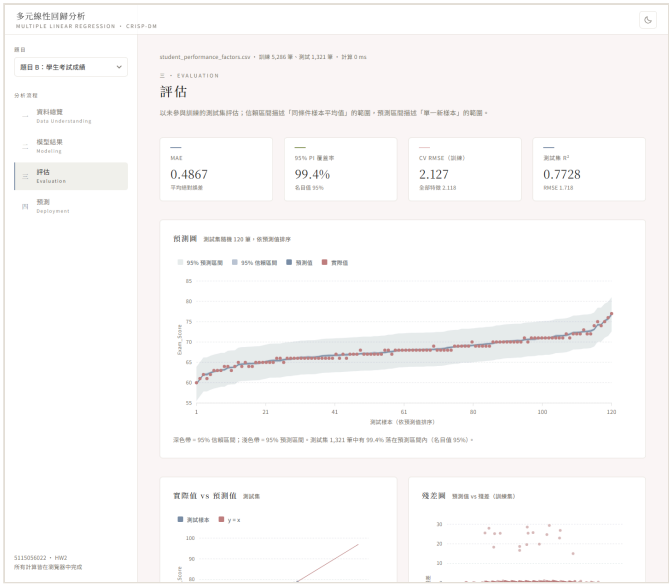


圖 W-2　評估頁：預測圖含 95% 信賴區間與預測區間

五、GPT 輔助內容（使用 Claude Code 與 ChatGPT）

GPT 輔助內容（Claude Code）

本作業的程式與分析在 AI 助手 Claude Code（Anthropic）協助下完成，完整對話紀錄另附 PDF。

AI 協助的部分：

- 依作業規定（10–20 個特徵）搜尋並以 Kaggle CLI 下載候選資料集，實際檢查欄位、缺失值與基準 R^2，協助排除不適合的 `flood.csv`。
- 撰寫 notebook 的分析流程（前處理、5 種特徵選擇、OLS／Ridge／Lasso、CI／PI、假設檢查），並逐一核對結論文字與實際輸出。
- 產生 Kaggle 提交檔、換算排行榜名次。
- 撰寫互動網頁與其驗證測試，部署到 GitHub。

本人的決策與確認：以作業內容（10–20 個特徵）為準、選定兩個題目、加入 Kaggle 競賽並提交、指定網頁的版型與視覺規格、確認上傳到 GitHub 的檔案。

附件：AI 對話紀錄 PDF（與 Claude Code 的完整對話）。

GPT 輔助內容（ChatGPT）

動工前另以 ChatGPT 評估「資料集是否符合作業要求」，以下為其回覆重點節錄。

需求	可行性	ChatGPT 建議的做法
CRISP-DM 六階段	可完成	每個階段都要有實際產出，不能只列標題
特徵選擇	可完成	相關係數、Permutation Importance、RFE
模型評估	可完成	R^2、RMSE、MAE，並比較不同模型
預測圖、信賴／預測區間	可完成	線性迴歸用 OLS 推論；非線性模型用 Bootstrap 或 Conformal Prediction；報告涵蓋率與平均區間寬度
下拉選單切換兩題	可完成	共用同一套分析模組，切換時只換設定與資料
輸入任意資料集網址	有條件可完成	限公開 CSV、由使用者指定目標欄位；須處理 CORS、空值／文字／常數欄位、網址協定與檔案大小限制

- **題目選擇：**建議題目 A 用 Flood Prediction（20 個數值特徵，資料量大，網頁端宜抽樣繪圖），題目 B 用 Student Performance Factors（6,607 筆、19 個混合型特徵，可展示缺失值處理與類別編碼，須排除目標洩漏欄位）。
- **不優先採用 `flood.csv`：**測試得 $R^2 = 1.0$、RMSE = 0，須檢查目標是否由特徵直接算出或有資料洩漏；若確認是特徵的線性公式，宜改選有實際預測誤差的資料集。
- **CI 與 PI 的區別：**信賴區間估計平均反應值的不確定性；預測區間估計單一新樣本的範圍，包含個體變異，因此較寬。

採納情形：採用其題目配置與排除 `flood.csv` 的建議；特徵選擇納入 Permutation Importance 與 RFE；以 OLS 計算 95% CI／PI，並檢查測試集涵蓋率；網頁的自訂 CSV 由使用者指定目標欄位。本作業主題為多元線性迴歸，因此未採用 Random Forest／Conformal Prediction 等非線性模型的區間估計。

GPT 輔助內容（ChatGPT）：網頁驗證

網頁完成後，請 ChatGPT「進行功能與數據等驗證」。ChatGPT 讀了公開頁面、README 與 `web/js` 原始碼，但無法實際操作瀏覽器。以下為其指出的問題，以及本人請 Claude Code 實際查證的結果。

ChatGPT 指出的問題	查證結果	處理
交叉驗證的特徵選擇有資料洩漏：排序用整個訓練集算出，再算 CV RMSE（列為高優先）	屬實，但影響可忽略：在每一折內重新排序後重算，CV 曲線最多差 1–2%，選出的 k 幾乎不變，測試集 RMSE 差 ≤ 0.003；測試集未參與選擇	報告加註「方法限制」
Durbin-Watson 判定「通過」不恰當：隨機切分的橫斷面資料，順序沒有意義	屬實，原本的結論說法有誤導	網頁、notebook、報告改為「僅供參考」
特徵選擇後的係數區間未反映選擇的不確定性	屬實（題目 A 保留全部特徵，不受影響）	報告加註「方法限制」
README 寫誤差 < 1e-12，測試門檻卻是 1e-6	部分屬實：實際執行比對測試，4 個案例 48 項全部通過，最大相對誤差 2.34×10^{-12}，略大於原寫的 10^{-12}	README、報告改為「約 2×10^{-12}」
覆蓋率應搭配平均區間寬度	屬實，目前未呈現	未採用（題目 B 覆蓋率偏高的原因已在 Evaluation 說明）
網頁導覽只呈現 4 個 CRISP-DM 階段	屬實；notebook 與報告為完整六階段	未採用

另外查證：線上部署的 `index.html`、`app.js`、`stats.js`、`mlr.js` 與本機版本內容一致。

六、NotebookLM 研究摘要

NotebookLM 摘要

以下為 NotebookLM 依筆記本來源產生的研究摘要原文（方括號為 NotebookLM 的來源引註）。

在洪水機率預測（Kaggle Playground S4E5）競賽中，未進行複雜特徵工程前的單一基礎模型（如 CatBoost、XGBoost、LightGBM 等）R^2 表現約在 0.766 至 0.846 之間 [1][2]。頂尖參賽者透過特徵工程將最佳單一模型的 R^2 提升至約 0.86933 [3]。關鍵的特徵工程手法包括計算每筆資料列的特徵總和（sum）、標準差（std）、最大值（max）、沿特徵軸排序（sorted features）、高於特定門檻值的特徵計數（count features），以及對特徵總和進行目標編碼（target encoder）與目標轉換 [4]。主要採用的模型包含 CatBoost、XGBoost、LightGBM、PyBoost 等多種梯度提升樹（GBM）與 AutoGluon 自動機器學習工具 [5][6]。最後透過嶺回歸（Ridge Regression）或線性回歸（Linear Regression）對折外預測（OOF）進行加權融合與前向特徵選擇，最終將整體 R^2 成功提升至 0.86943 [3]。

在學生成績資料（Student Performance Factors）的多元線性回歸研究中，研究者基於 6,607 筆觀察值分析影響學生考試成績（Exam Score）的決定因素 [9][10]。模型涵蓋 6 個自變數，包括學術因素（週學習時數、出席率、先前成績、家教輔導次數）與家庭及學習環境因素（家長參與度、學習資源取得管道）[9][11]。分析顯示該回歸模型整體達到統計顯著（$F = 1601$, $p < 0.001$），判定係數 R^2 為 0.660，即模型可解釋 66.0% 的考試成績變異 [9][10]。局部檢定顯示所有 6 個變數對成績均有顯著影響（$p < 0.001$），其中家教輔導次數（係數 0.504）、學習時數與出席率對成績有顯著正面拉升作用，而低家長參與度與低資源取得則顯著負向影響成績 [10][12]。研究結論指出，學生學術成就屬於多維度表現，除個人學習努力外，家庭支持與學習環境資源亦為極其關鍵的影響因子 [9][13]。

NotebookLM 來源：Kaggle S4E5 第 1、2 名解法（複製文字）；github.com/nhamhung/flood-prediction；github.com/surajwate/S4E5-Flood-Prediction-Dataset；IJNMT 論文 PDF（Student Performance Factors 多元線性回歸）。

提問：「請只根據來源內容，撰寫一份 200 字以上的繁體中文研究摘要，分兩段：第一段整理洪水機率預測（Kaggle Playground S4E5）的主流解法，包括特徵工程、使用的模型與融合方式、達到的 R^2；第二段整理學生成績資料（Student Performance Factors）的多元線性回歸研究，包括使用的變數、顯著因素、R^2 與結論。來源沒有提到的內容請不要推測。」

七、網路上主流或更優解法之比較與說明

題目 A：Kaggle Playground S4E5

解法	做法重點	Public R^2
本作業	20 個原始特徵＋OLS	0.84458
排行榜中約 450 隊	分數集中在 0.8446 附近，與本作業相同，相當於「原始特徵＋線性關係」的上限	≈ 0.8446
GitHub：surajwate	比較 Linear Regression、Random Forest、CatBoost，未做總和特徵；最佳為 CatBoost	CV 0.846
GitHub：nhamhung	以列總和、離散度、偏態、排序值等「列層級統計」為特徵，LightGBM＋XGBoost＋CatBoost 非負權重混合；SHAP 顯示 93% 的判斷來自列總和	Private 0.86893 約第 207 名
第 1 名（aldparis）	以「列總和」作為強訊號，多模型集成，並以正權重、無截距的 LinearRegression 組合各模型	0.86943
第 2 名（Peaky Blenders）	多層混合（blends of blends）	0.86943 Private 0.86902

差距的原因：競賽討論區指出，把 20 個特徵加總後對目標作圖，特定的總和值有較高的洪水機率；決策樹需要大量分支才能找出「20 個特徵加總等於某值」的規則，而線性回歸的係數本來就幾乎相同，等於「係數 × 總和＋截距」。這與本作業「20 個係數都約 0.00565」的發現完全一致，也說明了 0.8446 是線性模型在原始特徵上的上限。surajwate 的實驗更直接佐證：沒有總和特徵時，CatBoost（CV R^2 0.846）與本作業的線性回歸（0.845）幾乎相同——**關鍵在特徵工程，而不是換成更複雜的模型**。要再提升，必須針對總和建立非線性特徵（例如總和的分組、標準差、排序統計量），nhamhung 即以此達到 0.869。

題目 B：Student Performance Factors

來源	做法	結果
本作業	19 個特徵（one-hot 後 27 欄）多元線性回歸＋特徵選擇	測試 R^2 0.764–0.770
IJNMT 期刊論文（2026）	同一資料集的多元線性回歸	R^2 0.660；讀書時數、出席率、前次成績、輔導次數皆顯著為正
CMU 課程專題	只用出席率的簡單線性回歸	出席率係數 0.1958（本作業多元模型為 0.199，方向與大小一致）

比較：本作業的 R^2 高於論文的 0.660。論文只用 6 個自變數（讀書時數、出席率、前次成績、輔導次數、家長參與、資源取得），本作業另外納入家庭收入、同儕影響、動機、師資、網路、學習障礙等類別因素，各有約

0.5–1.1 分的效應，因而提升解釋力。可能的更優作法：由於誤差集中在約 0.5% 的高分離群值，可改用 Huber 等穩健回歸、或先辨識離群樣本再建模，使一般學生的預測區間更貼近實際（目前 PI 覆蓋率 99.5% 偏保守）。

本作業與網路解法的對照

主題	網路解法	本作業	解讀
洪水：未做特徵工程	單一 GBM 模型 R^2 0.766–0.846	OLS 0.845（Kaggle Public 0.84458）	線性回歸已達到未做特徵工程時的最佳水準
洪水：前段解法	特徵總和、std、max、排序、門檻計數＋多種 GBM 融合，R^2 0.86943	20 個係數皆約 0.00565，目標由特徵總和決定	本作業的係數分析解釋了「特徵總和」為何是關鍵
學生成績：變數	6 個自變數	19 個特徵（one-hot 後 27 欄），特徵選擇後 21–27 欄	多納入家庭收入、同儕影響、動機等類別因素
學生成績：R^2	0.660	測試集 0.764–0.770	多出的類別因素（家庭收入、同儕、動機、師資、網路等）各有約 0.5–1.1 分的效應，提升解釋力
學生成績：輔導次數係數	0.504	0.511	方向與大小一致，結論互相印證

八、結論

- 同一套「前處理 → 特徵選擇 → OLS → 假設檢查 → CI／PI」流程能套用到結構完全不同的兩份資料，也是網頁「輸入任意 CSV」功能的基礎。
- 題目 A 的特徵選擇證明 20 個特徵都不能刪，係數顯示目標由特徵總和決定；這同時解釋了 Kaggle 排行榜上線性模型（0.8446）與前段解法（0.869）的差距。
- 題目 B 的線性模型對一般學生極準（98% 誤差在 ±1.3 分內），限制來自少數離群值；這也讓 OLS 的預測區間偏保守，是穩健回歸可以改進之處。

參考資料

1. Kaggle Playground Series S4E5：https://www.kaggle.com/competitions/playground-series-s4e5
2. S4E5 第 1 名解法：https://www.kaggle.com/competitions/playground-series-s4e5/writeups/aldparis-1st-place-solution
3. S4E5 第 2 名解法：https://www.kaggle.com/competitions/playground-series-s4e5/writeups/peaky-blenders-2nd-place-solution-team-peaky-blend
4. S4E5 第 4 名解法：https://www.kaggle.com/competitions/playground-series-s4e5/writeups/4th-place-solution-hill-climbing-through-the-noise
5. S4E5 討論（特徵總和）：https://www.kaggle.com/competitions/playground-series-s4e5/discussion/499274
6. nhamhung/flood-prediction（列層級統計特徵、SHAP）：https://github.com/nhamhung/flood-prediction

7. surajwate/S4E5-Flood-Prediction-Dataset（Linear Regression／Random Forest／CatBoost 比較）：https://github.com/surajwate/S4E5-Flood-Prediction-Dataset
8. Student Performance Factors：https://www.kaggle.com/datasets/lainguyn123/student-performance-factors
9. IJNMT 論文（同資料集多元線性回歸）：https://ejournals.umn.ac.id/index.php/IJNMT/article/view/4762
10. CMU 課程專題（Exam_Score 回歸）：https://www.stat.cmu.edu/capstoneresearch/fall2024/315files_f24/team5.html