AIoT · HW2 · MULTIPLE LINEAR REGRESSION

多元線性回歸分析：洪水機率與學生成績預測

以 CRISP-DM 流程，對兩個 Kaggle 資料集完成特徵選擇、模型評估與信賴區間／預測區間分析

姓名	邱勇嘉
學號	5115056022
主程式	`5115056022_hw2.ipynb`
GitHub	github.com/hobartXIII/HW2-Multiple-Linear-regression
互動網頁	hobartxiii.github.io/HW2-Multiple-Linear-regression
Kaggle 成績	Playground S4E5：Public R^2 0.84458 / Private R^2 0.84426（換算約 1,850 / 2,794 名）

一、研究脈絡與資料集來源

本作業要以「原始特徵數 10–20 個」的 Kaggle 公開資料集練習多元線性回歸。為了同時呈現兩種典型情境，選擇兩個性質互補的資料集：題目 A 全為數值特徵、樣本極多，可專注於模型與區間估計；題目 B 數值與類別混合、含缺失值，需完整的前處理。

題目	資料集與來源	筆數	特徵	目標
A	Regression with a Flood Prediction Dataset（Kaggle Playground Series S4E5） kaggle.com/competitions/playground-series-s4e5 檔案下載自 naiyakhalid/flood-prediction-dataset（CC0）	1,117,957	20（數值）	`FloodProbability`（0–1）
B	Student Performance Factors kaggle.com/datasets/lainguyn123/student-performance-factors（CC0）	6,607	19（6 數值、13 類別）	`Exam_Score`

資料集篩選過程：原先考慮的 50,000 筆版本 `flood.csv`，以 OLS 檢查時測試集 $R^2 = 1.000$、RMSE = 0，代表目標值是 20 個特徵的精確線性組合，無法做不確定性分析，因此改用含雜訊的競賽版 `train.csv`。另檢查了 Life Expectancy (WHO)（缺失 2,563 格、R^2 0.57）與 Seoul Bike Sharing（R^2 0.53，非線性強），最後選定上述兩者。兩個資料集都是合成資料，結論僅用於方法練習，不代表真實世界的效果大小。

二、CRISP-DM 分析流程：題目 A 洪水機率

1. Business Understanding

依季風強度、都市化、排水系統、堤防品質等 20 項指標（0–18 的評分）預測地區洪水機率，讓防災單位排序高風險地區、分配改善預算。競賽評分指標為 R^2，因此以測試集 R^2 與 RMSE 為主要指標，並以預測區間說明

單筆預測的不確定性。

2. Data Understanding

- 無缺失值、無重複列；目標值近似常態，90% 落在 0.42–0.59。
- 每個特徵與目標的相關係數都在 0.178–0.190 之間，沒有主導特徵；特徵之間幾乎不相關（$|r| < 0.02$），共線性風險低。

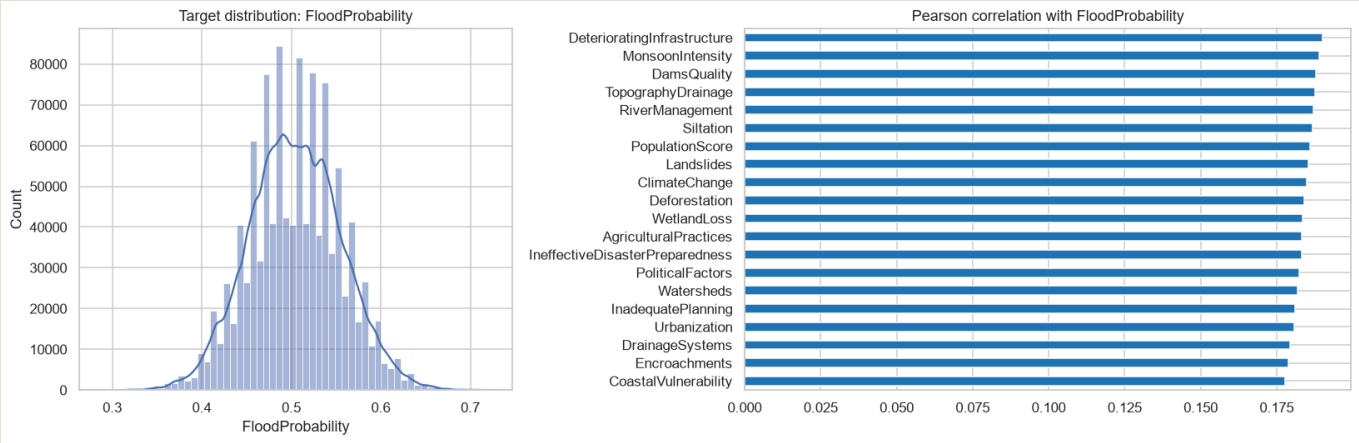


圖 A-1　目標分布與各特徵的相關係數

3. Data Preparation

移除流水號 `id`；80/20 切分（`random_state=42`），之後所有特徵選擇、標準化與超參數調整只用訓練集，避免資料洩漏。特徵選擇在訓練集中抽樣 60,000 筆進行（加速），最終模型使用完整訓練集（894,365 筆）。

4. Modeling：特徵選擇與模型比較

比較 5 種特徵選擇方法：SelectKBest（F 檢定）、RFE、Sequential Forward Selection、Lasso path、Permutation importance，計算每個 k 的 5-fold CV RMSE，選擇規則為「CV RMSE 在最佳值 0.5% 以內的最少特徵」。

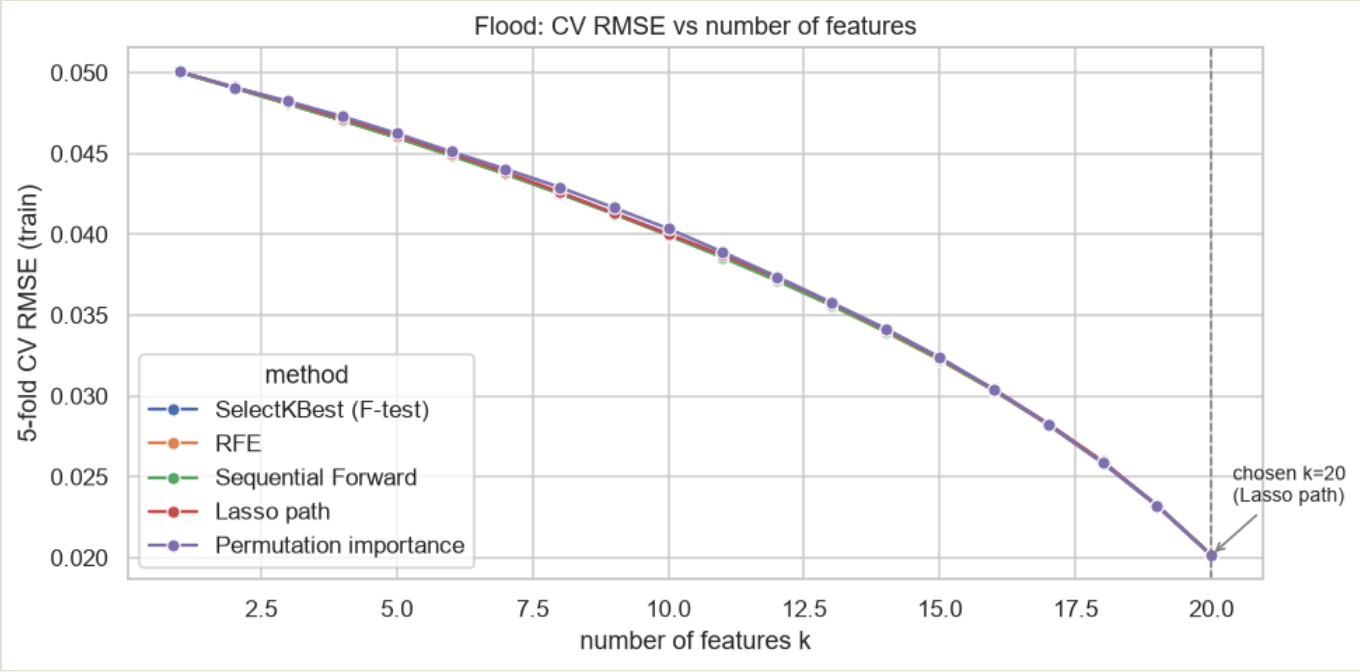


圖 A-2　特徵數 k 與 CV RMSE：五種方法到 k = 20 都持續下降（k = 19→20 仍由 0.0232 降到 0.0202）

結果是 **k = 20，全部保留**：每個特徵貢獻相同的訊號，刪掉任何一個都會讓誤差明顯上升，此處特徵選擇的價值在於「證明不能刪」。OLS、RidgeCV、LassoCV 的測試集表現完全相同（RMSE 0.02008、R^2 0.84488），因特徵互不相關，正則化沒有幫助。

係數的發現：20 個係數全部落在 0.0056–0.0057、信賴區間彼此重疊，截距 −0.0533。模型實際上是 `FloodProbability ≈ 0.00565 × (20 項評分總和) − 0.053`，各因素同等重要。

5. Evaluation

指標（測試集 223,592 筆）	MAE	MSE	RMSE	R^2	Adj. R^2	95% PI 覆蓋率
OLS（20 特徵）	0.01579	0.00040	0.02008	0.84488	0.84486	94.6%

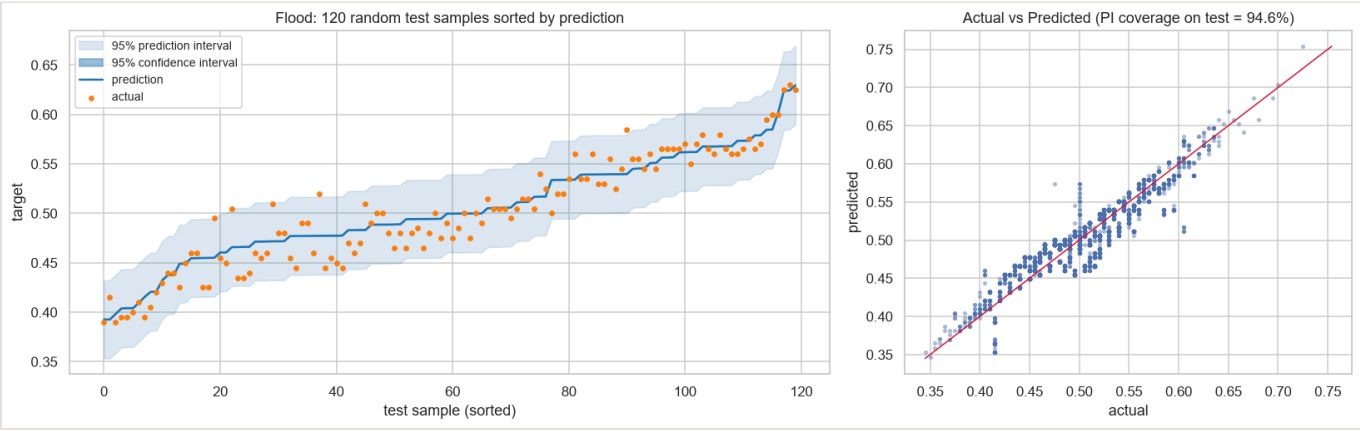


圖 A-3　預測圖：120 筆測試樣本依預測值排序，深色帶為 95% 信賴區間、淺色帶為 95% 預測區間；右圖為實際值對預測值

預測區間的實際覆蓋率 94.6%，接近名目 95%，代表區間寬度估計合理；信賴區間因樣本數大而窄到幾乎看不見。

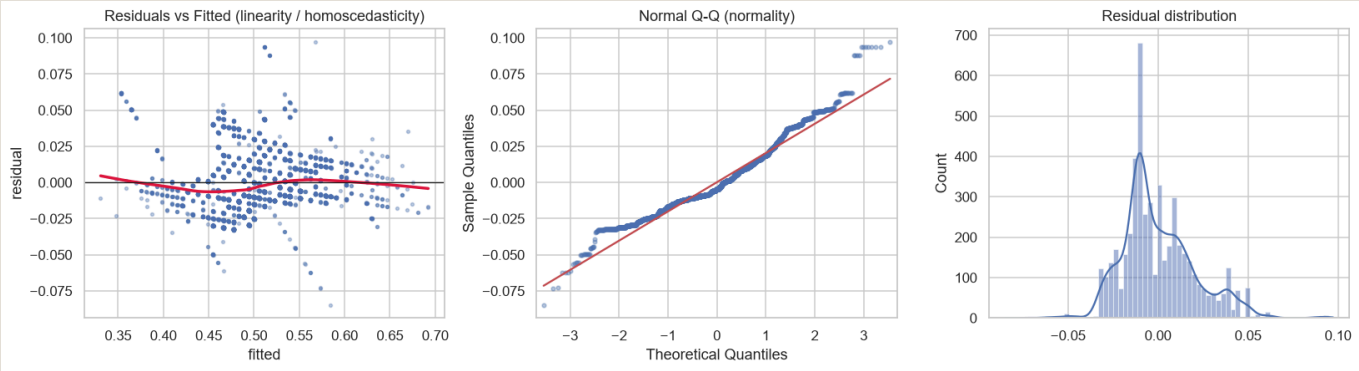


圖 A-4　殘差診斷：殘差 vs 配適值、Q-Q 圖、殘差分布

假設	檢查	數值	判斷
獨立性	Durbin-Watson	2.000	僅供參考：資料為隨機切分的橫斷面資料，列的順序沒有時間意義，DW 必然接近 2；獨立性由抽樣方式保證
同質變異	Breusch-Pagan p	≈ 0	不通過（近 90 萬筆時微小偏差也顯著）
常態性	Jarque-Bera p	≈ 0	不通過；Q-Q 圖兩端偏離
無共線性	最大 VIF	1.004	通過
線性	殘差圖 LOWESS	—	輕微 S 形，存在線性模型未捕捉的非線性

Kaggle 提交結果與名次

以全部 1,117,957 筆重新估計後，對 Kaggle 測試集（745,305 筆）預測並提交（late submission）：**Public R^2 0.84458、Private R^2 0.84426**，與本機測試集 R^2 0.845 幾乎相同，證實評估方式可信。以分數對照 Public 排行榜（2,794 隊），換算名次約為 **第 1,850 名**。

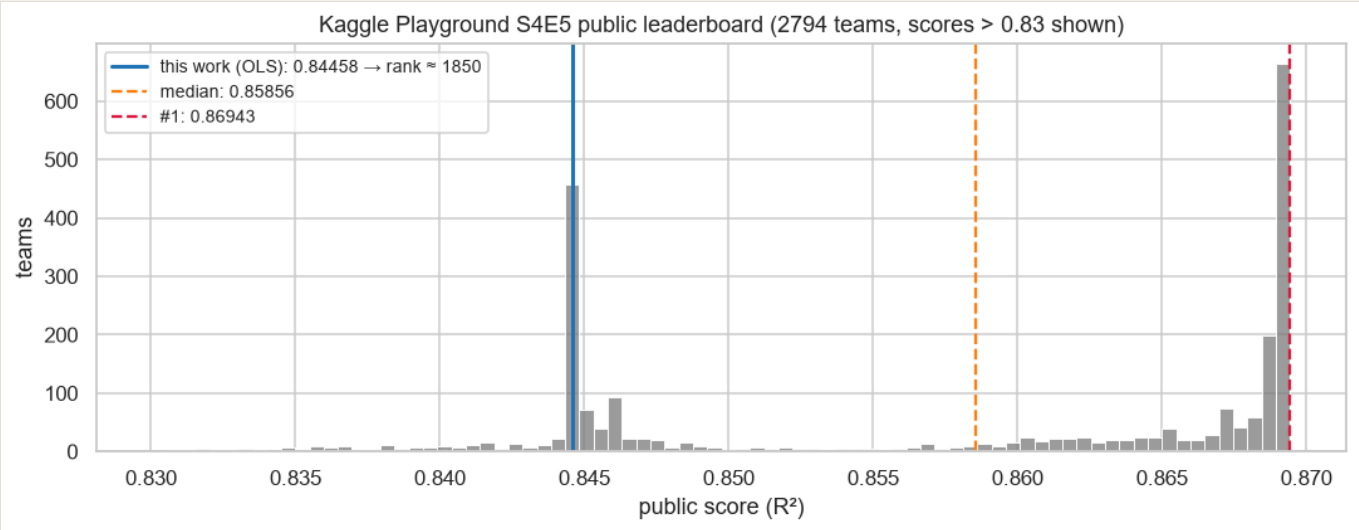


圖 A-5　Public 排行榜分數分布：本作業分數（藍線）位於約 450 隊聚集的 0.8446 一群；另約 660 隊聚集在 0.869

6. Deployment

模型（前處理器＋選定特徵＋OLS）以 joblib 存檔，`predict_with_interval()` 可對新資料輸出預測值與 95% CI／PI；同一流程也實作於互動網頁（第四節）。

三、CRISP-DM 分析流程：題目 B 學生考試成績

1. Business Understanding

依讀書時數、出席率、家長參與、家庭收入、師資品質等 19 項因素預測期末考成績，讓學校提早找出可能表現不佳的學生，並了解哪些「可改變的因素」影響最大。以 RMSE（單位為分數，易解釋）與 R^2 為指標，同時重視係數的可解釋性。

2. Data Understanding

- 6,607 筆；`Teacher_Quality`、`Parental_Education_Level`、`Distance_from_Home` 共 235 格缺失。
- `Attendance`（r = 0.58）與 `Hours_Studied`（r = 0.45）是最強的數值因素；`Sleep_Hours`、`Physical_Activity` 幾乎無關。
- 類別特徵中 `Access_to_Resources`、`Parental_Involvement` 的高低組差距明顯，`Gender`、`School_Type` 幾乎沒有差異。
- 目標 90% 落在 62–73 分，右尾有少數 80–101 分的離群值；有 1 筆 101 分超過滿分，因只有 1 筆而保留並註明。

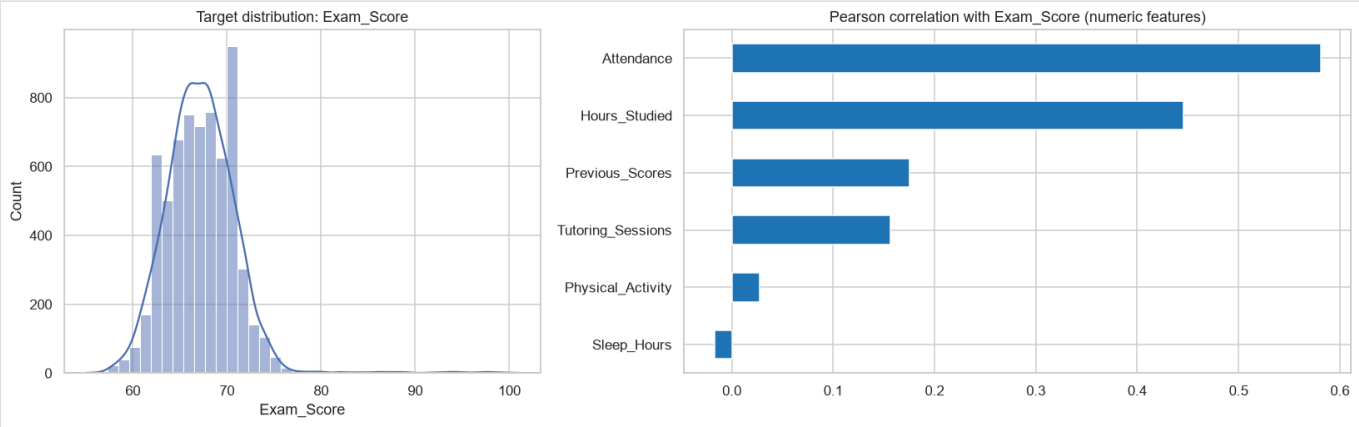


圖 B-1　目標分布與數值特徵的相關係數

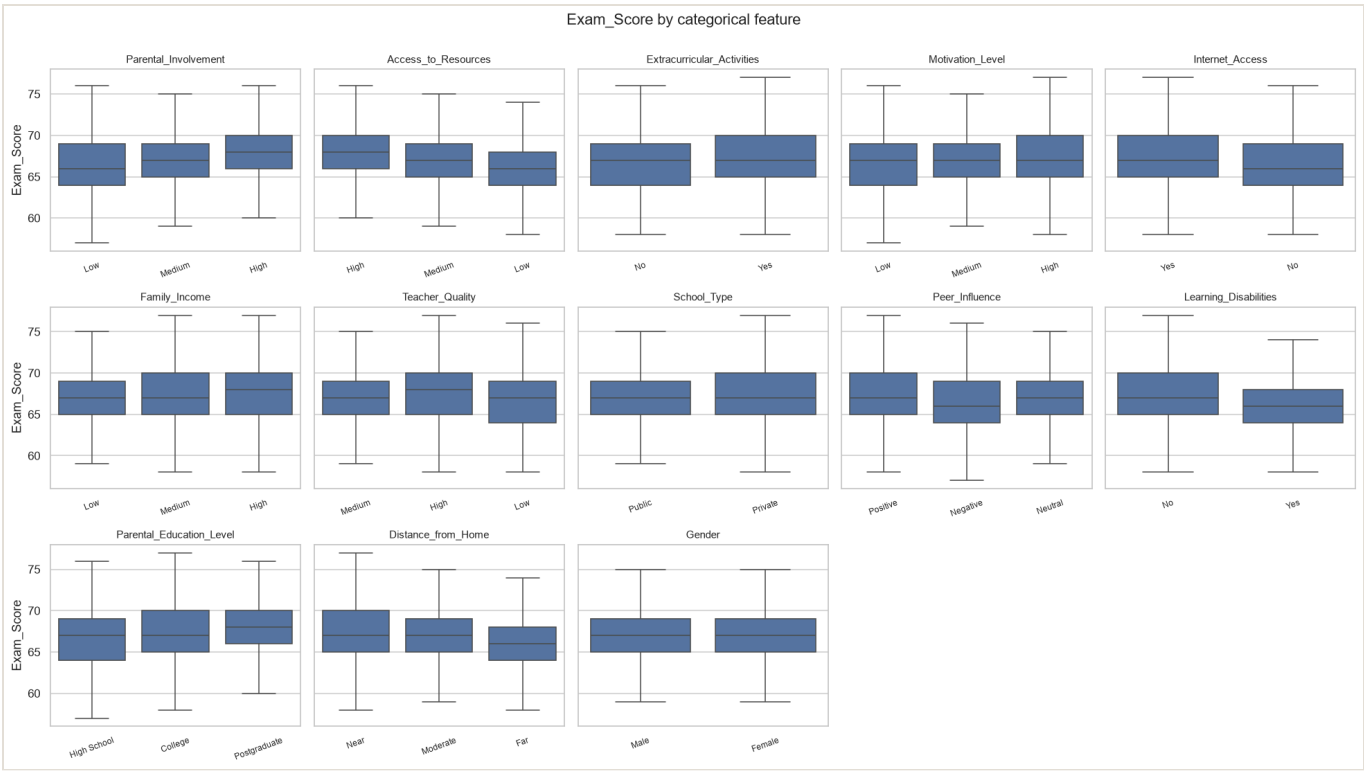


圖 B-2　各類別特徵下的成績分布

3. Data Preparation

80/20 切分後，只用訓練集計算補值（數值：中位數、類別：眾數）與類別水準；類別欄做 one-hot 編碼並刪除第一個類別（避開虛擬變數陷阱），19 個原始特徵展開為 27 個欄位。

4. Modeling：特徵選擇與模型比較

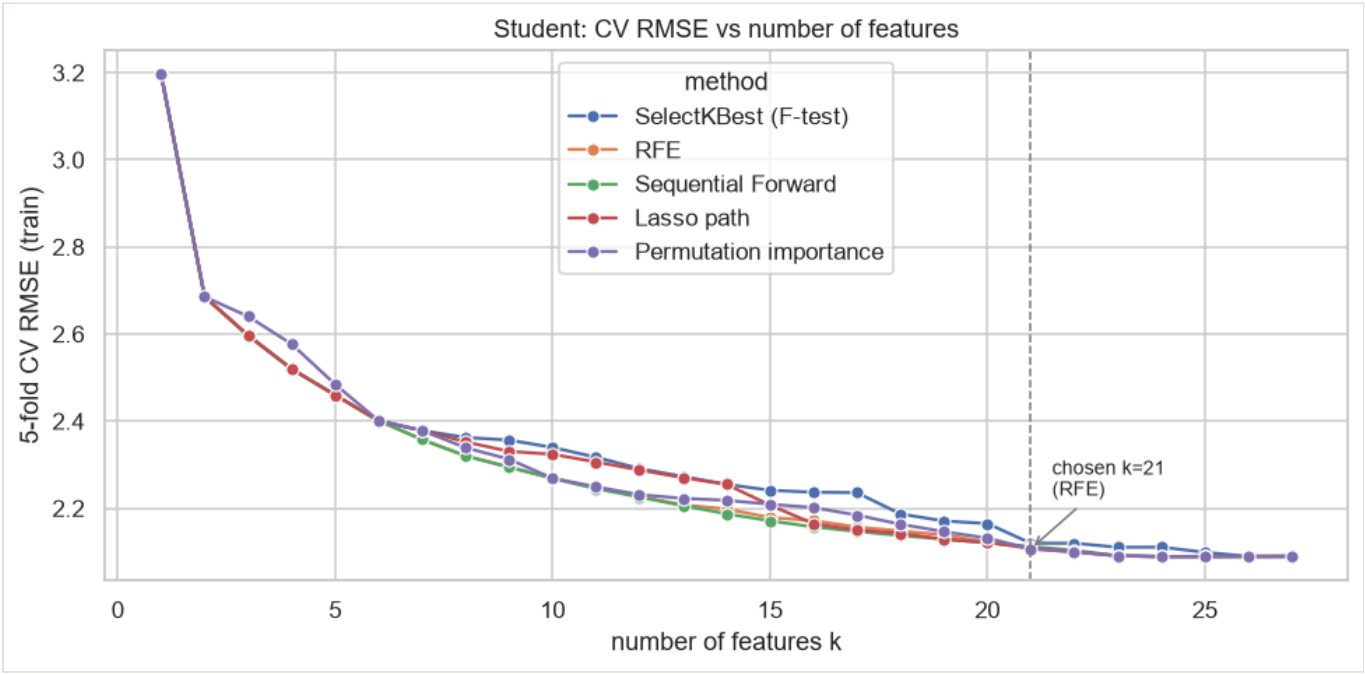


圖 B-3　特徵數 k 與 CV RMSE：前 6 個特徵加入後快速下降，之後趨平；k = 7–20 間多變量方法（Forward、RFE）優於 SelectKBest

5 種方法的前 6 名幾乎一致（出席率、讀書時數、前次成績、輔導次數、資源取得、家長參與）。以「CV RMSE 在最佳值 1% 以內的最少特徵」選出 RFE 的 **k = 21**，刪除 `Gender`、`School_Type`、`Sleep_Hours`、

`Physical_Activity` 與兩個效應較小的類別水準。

模型（測試集 1,322 筆）	k	MAE	RMSE	R^2	Adj. R^2	CV RMSE
OLS（全部特徵）	27	0.452	1.804	0.770	0.765	2.090
OLS（RFE 選出）	21	0.543	1.825	0.764	0.761	2.107
RidgeCV	27	0.452	1.804	0.770	0.765	2.090
LassoCV	27	0.452	1.804	0.770	0.765	2.090

精簡的代價：RMSE 與 R^2 相近，但 MAE 由 0.452 升到 0.543（約 +20%），因為被刪掉的兩個類別水準其實有小而真實的效應——刪掉一個虛擬變數等於把該水準併入基準類別。重視準確度可用全特徵模型，重視精簡與解釋則 k = 21 的損失很小。Ridge／Lasso 沒有更好，表示誤差不是來自過擬合。

方法限制：

- **CV 曲線略為樂觀：**SelectKBest、RFE 等排序是用整個訓練集算出後，再計算 5-fold CV RMSE，驗證折的資料間接參與了排序。改成在每一折內重新排序後重算，兩題的 CV 曲線最多相差約 1–2%，選出的 k 幾乎不變，測試集 RMSE 差異 ≤ 0.003。測試集從未參與特徵選擇，所以測試集指標不受影響。
- **係數區間是條件區間：**係數的信賴區間是在「特徵已選定」條件下的 OLS 區間，沒有計入特徵選擇本身的不確定性，可能略窄。題目 A 保留全部 20 個特徵，不受此影響。

主要係數（原始單位）：出席率每多 1 個百分點 +0.199 分；每週讀書每多 1 小時 +0.294 分；每多一次輔導 +0.511 分；資源取得「低」比「高」少 2.11 分；家長參與「低」比「高」少 2.00 分（p 值皆 < 0.0001）。

5. Evaluation

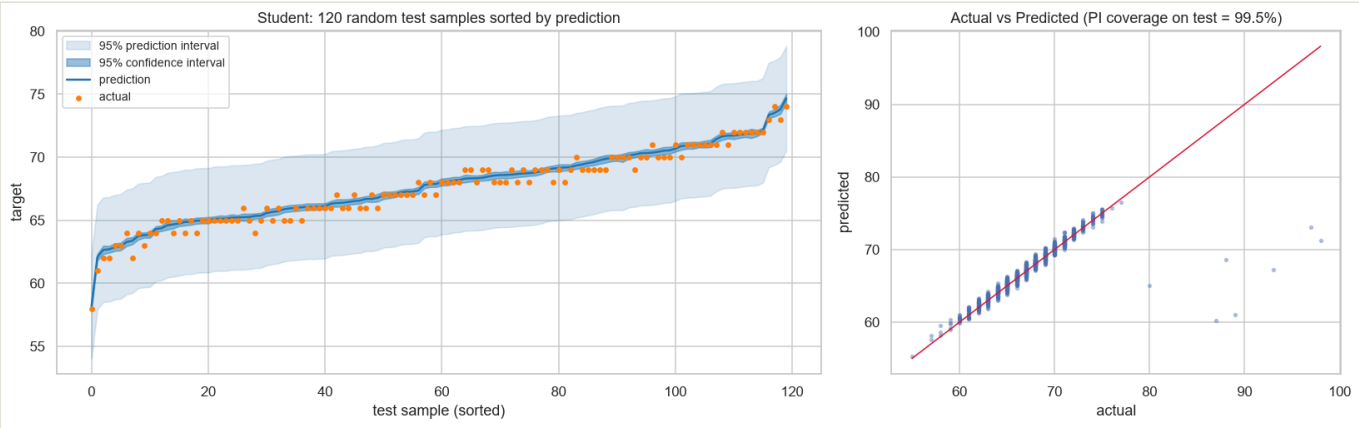


圖 B-4　預測圖（95% 信賴區間與預測區間）與實際值對預測值：少數學生實際 80–100 分、模型只預測 60–73 分

- **誤差幾乎全來自離群值：**98% 的測試殘差落在 ±1.3 分以內，|殘差| > 5 分的只有 0.5%。一般學生的分數幾乎就是各因素的線性加總，R^2 停在約 0.77 主要是這群離群值造成。
- **預測區間過寬：**覆蓋率 99.5% 高於名目 95%。OLS 的 PI 假設殘差常態，離群值把殘差標準差撐大到約 1.8，對一般學生而言 PI（約 ±4 分）過於保守。

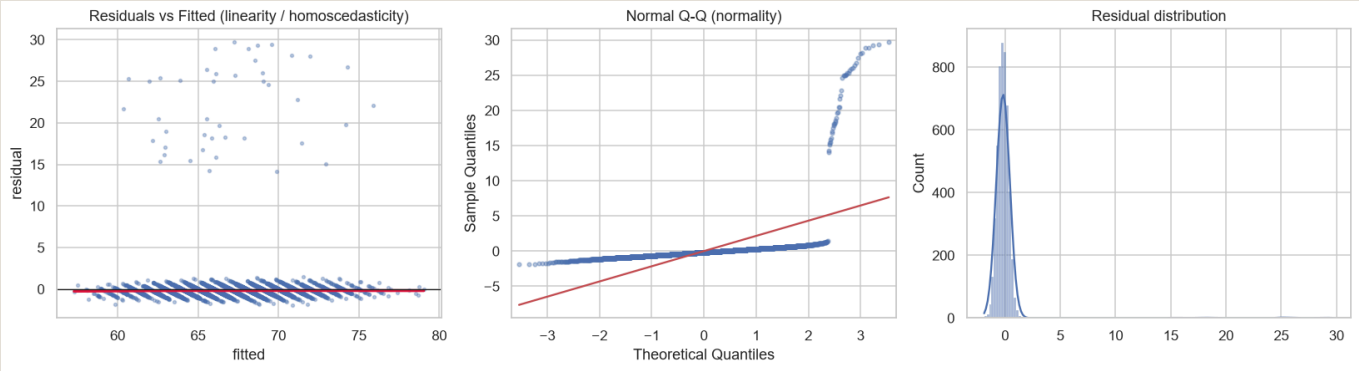


圖 B-5　殘差診斷：Q-Q 圖右上翹，為高分離群值造成的長右尾

假設	檢查	數值	判斷
獨立性	Durbin-Watson	1.949	僅供參考（理由同題目 A）
同質變異	Breusch-Pagan p	0.853	通過
常態性	Jarque-Bera p	≈ 0	不通過（長右尾）
無共線性	最大 VIF	1.86	通過

6. Deployment

模型存檔；對一位新學生（讀書 25 小時、出席 90%、家長參與高等）預測 74.01 分，95% CI 73.79–74.24、95% PI 69.87–78.15。CI 是「同條件學生的平均成績」範圍，PI 是「這一位學生」的範圍，所以 PI 寬得多。

四、加分功能：互動式網頁

網址：hobartxiii.github.io/HW2-Multiple-Linear-regression。純前端靜態網站（Tailwind CSS、Flowbite、ApexCharts、PapaParse），回歸運算全部在瀏覽器中以 JavaScript 完成，部署於 GitHub Pages。

- **下拉選單切換兩個題目**（加分 1）：側邊欄頂部切換題目 A／B，自動載入對應資料與預設目標。
- **輸入任意資料集網址**（加分 2）：貼上 CSV 網址（例如 50_Startups.csv）或拖曳上傳；自動判斷數值／類別欄、排除 ID 與高基數欄、one-hot 編碼與補值，再完成同樣的特徵選擇、OLS、CI／PI 與假設檢查。以 50_Startups 為例，自動選出 R&D Spend 與 Marketing Spend（k = 2），測試 R^2 0.946。
- **正確性驗證：**以相同切分與編碼和 Python statsmodels 比對 4 個案例，係數、標準誤、p 值、CI／PI、R^2、Durbin-Watson、Jarque-Bera、Breusch-Pagan、VIF 的最大相對誤差約 2×10^{-12}。

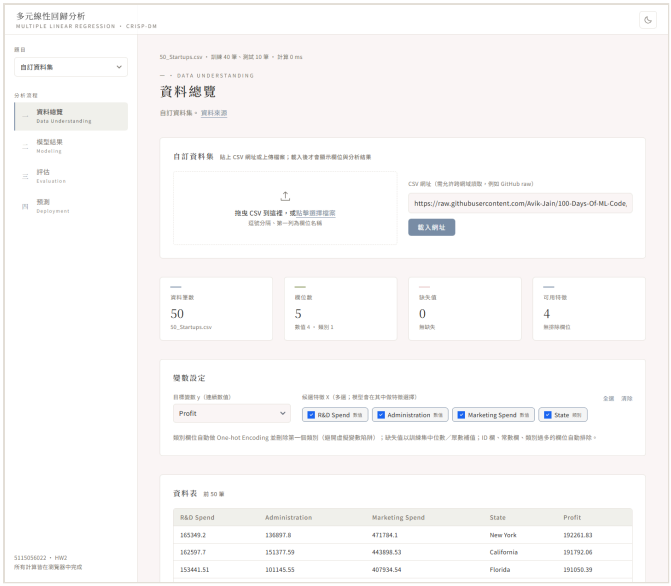


圖 W-1　輸入任意網址（50_Startups）後的資料總覽

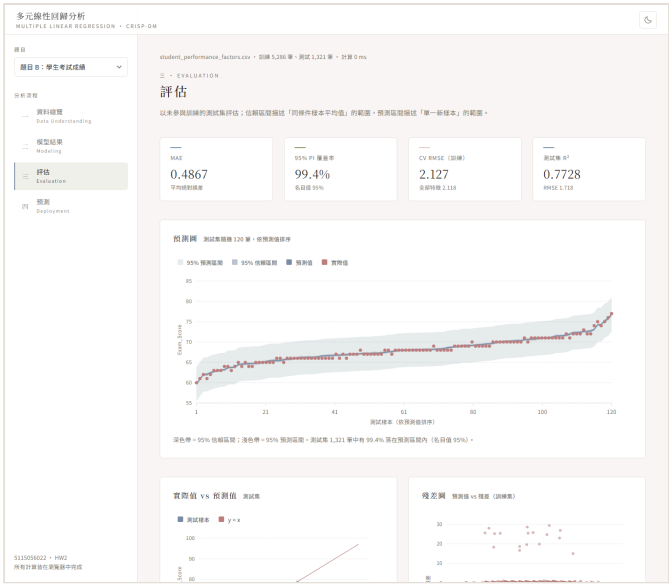


圖 W-2　評估頁：預測圖含 95% 信賴區間與預測區間

五、GPT 輔助內容（使用 Claude Code 與 ChatGPT）

GPT 輔助內容（Claude Code）

本作業的程式與分析在 AI 助手 Claude Code（Anthropic）協助下完成，完整對話過程見本報告附錄「GPT 對話過程」。

AI 協助的部分：

- 依作業規定（10–20 個特徵）搜尋並以 Kaggle CLI 下載候選資料集，實際檢查欄位、缺失值與基準 R^2，協助排除不適合的 `flood.csv`。
- 撰寫 notebook 的分析流程（前處理、5 種特徵選擇、OLS／Ridge／Lasso、CI／PI、假設檢查），並逐一核對結論文字與實際輸出。
- 產生 Kaggle 提交檔、換算排行榜名次。
- 撰寫互動網頁與其驗證測試，部署到 GitHub。

本人的決策與確認：以作業內容（10–20 個特徵）為準、選定兩個題目、加入 Kaggle 競賽並提交、指定網頁的版型與視覺規格（規格 prompt 另向 Claude 桌面版 Opus 5.5 詢問產生）、確認上傳到 GitHub 的檔案。

附錄「GPT 對話過程」第二部分為與 Claude Code 的對話。

GPT 輔助內容（ChatGPT）

動工前另以 ChatGPT 評估「資料集是否符合作業要求」，以下為其回覆重點節錄；與 ChatGPT 的完整對話（3 輪）見本報告附錄「GPT 對話過程」第一部分，分享連結：https://chatgpt.com/share/6ad48eb2-c608-83ee-85c9-3d6a29bc3dda。

需求	可行性	ChatGPT 建議的做法
CRISP-DM 六階段	可完成	每個階段都要有實際產出，不能只列標題
特徵選擇	可完成	相關係數、Permutation Importance、RFE
模型評估	可完成	R^2、RMSE、MAE，並比較不同模型
預測圖、信賴／預測區間	可完成	線性迴歸用 OLS 推論；非線性模型用 Bootstrap 或 Conformal Prediction；報告涵蓋率與平均區間寬度
下拉選單切換兩題	可完成	共用同一套分析模組，切換時只換設定與資料
輸入任意資料集網址	有條件可完成	限公開 CSV、由使用者指定目標欄位；須處理 CORS、空值／文字／常數欄位、網址協定與檔案大小限制

- **題目選擇：**建議題目 A 用 Flood Prediction（20 個數值特徵，資料量大，網頁端宜抽樣繪圖），題目 B 用 Student Performance Factors（6,607 筆、19 個混合型特徵，可展示缺失值處理與類別編碼，須排除目標洩漏欄位）。
- **不優先採用 `flood.csv`：**測試得 $R^2 = 1.0$、RMSE = 0，須檢查目標是否由特徵直接算出或有資料洩漏；若確認是特徵的線性公式，宜改選有實際預測誤差的資料集。
- **CI 與 PI 的區別：**信賴區間估計平均反應值的不確定性；預測區間估計單一新樣本的範圍，包含個體變異，因此較寬。

採納情形：採用其題目配置與排除 `flood.csv` 的建議；特徵選擇納入 Permutation Importance 與 RFE；以 OLS 計算 95% CI／PI，並檢查測試集涵蓋率；網頁的自訂 CSV 由使用者指定目標欄位。本作業主題為多元線性迴歸，因此未採用 Random Forest／Conformal Prediction 等非線性模型的區間估計。

GPT 輔助內容（ChatGPT）：網頁驗證

網頁完成後，請 ChatGPT「進行功能與數據等驗證」。ChatGPT 讀了公開頁面、README 與 `web/js` 原始碼，但無法實際操作瀏覽器。以下為其指出的問題，以及本人請 Claude Code 實際查證的結果。

ChatGPT 指出的問題	查證結果	處理
交叉驗證的特徵選擇有資料洩漏：排序用整個訓練集算出，再算 CV RMSE（列為高優先）	屬實，但影響可忽略：在每一折內重新排序後重算，CV 曲線最多差 1–2%，選出的 k 幾乎不變，測試集 RMSE 差 ≤ 0.003；測試集未參與選擇	報告加註「方法限制」
Durbin-Watson 判定「通過」不恰當：隨機切分的橫斷面資料，順序沒有意義	屬實，原本的結論說法有誤導	網頁、notebook、報告改為「僅供參考」
特徵選擇後的係數區間未反映選擇的不確定性	屬實（題目 A 保留全部特徵，不受影響）	報告加註「方法限制」
README 寫誤差 < 1e-12，測試門檻卻是 1e-6	部分屬實：實際執行比對測試，4 個案例 48 項全部通過，最大相對誤差 2.34×10^{-12}，略大於原寫的 10^{-12}	README、報告改為「約 2×10^{-12}」
覆蓋率應搭配平均區間寬度	屬實，目前未呈現	未採用（題目 B 覆蓋率偏高的原因已在 Evaluation 說明）
網頁導覽只呈現 4 個 CRISP-DM 階段	屬實；notebook 與報告為完整六階段	未採用

另外查證：線上部署的 `index.html`、`app.js`、`stats.js`、`mlr.js` 與本機版本內容一致。之後另請 ChatGPT 提供可用於「自訂資料集」的公開 CSV（Concrete、Wine Quality、Auto MPG、Boston Housing），內容見附錄「GPT 對話過程」第一部分。

六、NotebookLM 研究摘要

NotebookLM 摘要

以下為 NotebookLM 依筆記本來源產生的研究摘要原文（方括號為 NotebookLM 的來源引註）。

在洪水機率預測（Kaggle Playground S4E5）競賽中，未進行複雜特徵工程前的單一基礎模型（如 CatBoost、XGBoost、LightGBM 等）R^2 表現約在 0.766 至 0.846 之間 [1][2]。頂尖參賽者透過特徵工程將最佳單一模型的 R^2 提升至約 0.86933 [3]。關鍵的特徵工程手法包括計算每筆資料列的特徵總和（sum）、標準差（std）、最大值（max）、沿特徵軸排序（sorted features）、高於特定門檻值的特徵計數（count features），以及對特徵總和進行目標編碼（target encoder）與目標轉換 [4]。主要採用的模型包含 CatBoost、XGBoost、LightGBM、PyBoost 等多種梯度提升樹（GBM）與 AutoGluon 自動機器學習工具 [5][6]。最後透過嶺回歸（Ridge Regression）或線性回歸（Linear Regression）對折外預測（OOF）進行加權融合與前向特徵選擇，最終將整體 R^2 成功提升至 0.86943 [3]。

在學生成績資料（Student Performance Factors）的多元線性回歸研究中，研究者基於 6,607 筆觀察值分析影響學生考試成績（Exam Score）的決定因素 [9][10]。模型涵蓋 6 個自變數，包括學術因素（週學習時數、出席率、先前成績、家教輔導次數）與家庭及學習環境因素（家長參與度、學習資源取得管道）[9][11]。分析顯示該回歸模型整體達到統計顯著（$F = 1601$, $p < 0.001$），判定係數 R^2 為 0.660，即模型可解釋 66.0% 的考試成績變異 [9][10]。局部檢定顯示所有 6 個變數對成績均有顯著影響（$p < 0.001$），其中家教輔導次數（係數 0.504）、學習時數與出席率對成績有顯著正面拉升作用，而低家長參與度與低資源取得則顯著負向影響成績 [10][12]。研究結論指出，學生學術成就屬於多維度表現，除個人學習努力外，家庭支持與學習環境資源亦為極其關鍵的影響因子 [9][13]。

NotebookLM 來源：Kaggle S4E5 第 1、2 名解法（複製文字）；github.com/nhamhung/flood-prediction；github.com/surajwate/S4E5-Flood-Prediction-Dataset；IJNMT 論文 PDF（Student Performance Factors 多元線性回歸）。

提問：「請只根據來源內容，撰寫一份 200 字以上的繁體中文研究摘要，分兩段：第一段整理洪水機率預測（Kaggle Playground S4E5）的主流解法，包括特徵工程、使用的模型與融合方式、達到的 R^2；第二段整理學生成績資料（Student Performance Factors）的多元線性回歸研究，包括使用的變數、顯著因素、R^2 與結論。來源沒有提到的內容請不要推測。」

七、網路上主流或更優解法之比較與說明

題目 A：Kaggle Playground S4E5

解法	做法重點	Public R^2
本作業	20 個原始特徵＋OLS	0.84458
排行榜中約 450 隊	分數集中在 0.8446 附近，與本作業相同，相當於「原始特徵＋線性關係」的上限	≈ 0.8446
GitHub：surajwate	比較 Linear Regression、Random Forest、CatBoost，未做總和特徵；最佳為 CatBoost	CV 0.846
GitHub：nhamhung	以列總和、離散度、偏態、排序值等「列層級統計」為特徵，LightGBM＋XGBoost＋CatBoost 非負權重混合；SHAP 顯示 93% 的判斷來自列總和	Private 0.86893 約第 207 名
第 1 名（aldparis）	以「列總和」作為強訊號，多模型集成，並以正權重、無截距的 LinearRegression 組合各模型	0.86943
第 2 名（Peaky Blenders）	多層混合（blends of blends）	0.86943 Private 0.86902

差距的原因：競賽討論區指出，把 20 個特徵加總後對目標作圖，特定的總和值有較高的洪水機率；決策樹需要大量分支才能找出「20 個特徵加總等於某值」的規則，而線性回歸的係數本來就幾乎相同，等於「係數 × 總和＋截距」。這與本作業「20 個係數都約 0.00565」的發現完全一致，也說明了 0.8446 是線性模型在原始特徵上的上限。surajwate 的實驗更直接佐證：沒有總和特徵時，CatBoost（CV R^2 0.846）與本作業的線性回歸（0.845）幾乎相同——**關鍵在特徵工程，而不是換成更複雜的模型**。要再提升，必須針對總和建立非線性特徵（例如總和的分組、標準差、排序統計量），nhamhung 即以此達到 0.869。

題目 B：Student Performance Factors

來源	做法	結果
本作業	19 個特徵（one-hot 後 27 欄）多元線性回歸＋特徵選擇	測試 R^2 0.764–0.770
IJNMT 期刊論文（2026）	同一資料集的多元線性回歸	R^2 0.660；讀書時數、出席率、前次成績、輔導次數皆顯著為正
CMU 課程專題	只用出席率的簡單線性回歸	出席率係數 0.1958（本作業多元模型為 0.199，方向與大小一致）

比較：本作業的 R^2 高於論文的 0.660。論文只用 6 個自變數（讀書時數、出席率、前次成績、輔導次數、家長參與、資源取得），本作業另外納入家庭收入、同儕影響、動機、師資、網路、學習障礙等類別因素，各有約

0.5–1.1 分的效應，因而提升解釋力。可能的更優作法：由於誤差集中在約 0.5% 的高分離群值，可改用 Huber 等穩健回歸、或先辨識離群樣本再建模，使一般學生的預測區間更貼近實際（目前 PI 覆蓋率 99.5% 偏保守）。

本作業與網路解法的對照

主題	網路解法	本作業	解讀
洪水：未做特徵工程	單一 GBM 模型 R^2 0.766–0.846	OLS 0.845（Kaggle Public 0.84458）	線性回歸已達到未做特徵工程時的最佳水準
洪水：前段解法	特徵總和、std、max、排序、門檻計數＋多種 GBM 融合，R^2 0.86943	20 個係數皆約 0.00565，目標由特徵總和決定	本作業的係數分析解釋了「特徵總和」為何是關鍵
學生成績：變數	6 個自變數	19 個特徵（one-hot 後 27 欄），特徵選擇後 21–27 欄	多納入家庭收入、同儕影響、動機等類別因素
學生成績：R^2	0.660	測試集 0.764–0.770	多出的類別因素（家庭收入、同儕、動機、師資、網路等）各有約 0.5–1.1 分的效應，提升解釋力
學生成績：輔導次數係數	0.504	0.511	方向與大小一致，結論互相印證

八、結論

- 同一套「前處理 → 特徵選擇 → OLS → 假設檢查 → CI／PI」流程能套用到結構完全不同的兩份資料，也是網頁「輸入任意 CSV」功能的基礎。
- 題目 A 的特徵選擇證明 20 個特徵都不能刪，係數顯示目標由特徵總和決定；這同時解釋了 Kaggle 排行榜上線性模型（0.8446）與前段解法（0.869）的差距。
- 題目 B 的線性模型對一般學生極準（98% 誤差在 ±1.3 分內），限制來自少數離群值；這也讓 OLS 的預測區間偏保守，是穩健回歸可以改進之處。

參考資料

1. Kaggle Playground Series S4E5：https://www.kaggle.com/competitions/playground-series-s4e5
2. S4E5 第 1 名解法：https://www.kaggle.com/competitions/playground-series-s4e5/writeups/aldparis-1st-place-solution
3. S4E5 第 2 名解法：https://www.kaggle.com/competitions/playground-series-s4e5/writeups/peaky-blenders-2nd-place-solution-team-peaky-blend
4. S4E5 第 4 名解法：https://www.kaggle.com/competitions/playground-series-s4e5/writeups/4th-place-solution-hill-climbing-through-the-noise
5. S4E5 討論（特徵總和）：https://www.kaggle.com/competitions/playground-series-s4e5/discussion/499274
6. nhamhung/flood-prediction（列層級統計特徵、SHAP）：https://github.com/nhamhung/flood-prediction

7. surajwate/S4E5-Flood-Prediction-Dataset（Linear Regression／Random Forest／CatBoost 比較）：https://github.com/surajwate/S4E5-Flood-Prediction-Dataset
8. Student Performance Factors：https://www.kaggle.com/datasets/lainguyn123/student-performance-factors
9. IJNMT 論文（同資料集多元線性回歸）：https://ejournals.umn.ac.id/index.php/IJNMT/article/view/4762
10. CMU 課程專題（Exam_Score 回歸）：https://www.stat.cmu.edu/capstoneresearch/fall2024/315files_f24/team5.html

附錄：GPT 對話過程（一、ChatGPT 對話；二、Claude Code 對話），接在本頁之後。

HW2 GPT 對話過程

本文件包含兩部分：一、ChatGPT 對話；二、Claude Code 對話（接在第一部分之後）。

一、ChatGPT 對話

姓名 邱勇嘉 • 學號 5115056022 • 對話標題：資料集專題可行性評估 • 建立日期 2026-10-18
來源：ChatGPT 分享連結 https://chatgpt.com/share/6ad48eb2-c608-83ee-85c9-3d6a29bc3dda
共 3 則使用者訊息，內容由分享連結擷取後重新排版，文字未修改；ChatGPT 的網頁引用標記與示意圖片未保留，互動元件（下拉選單、勾選清單）以預設狀態呈現。
註：本作業為 HW2 期中作業；ChatGPT 回覆中的「期末專題」是其自行推測的用語，為保留原文未修改。

使用者

```
| Student        |         | 19，數值和類 | 235   | 0.7 |                |
  | Performance    | 6,607   | 別混合       | 格    | 70  | ✅             |
  | Factors        |         |              |       |     |                |

├────────────────────────┼─────────────┼──────────────────────┼─────────┼─────────┼
──────────────────────┤
  | Life           |         | 20（不含     | 2,56  | 0.5 | 可用，但前處理 |
  | Expectancy     | 2,938   | Country）    | 3 格  | 71  | 比較多         |
  | (WHO)          |         |              |       |     |                |

├────────────────────────┼─────────────┼──────────────────────┼─────────┼─────────┼
──────────────────────┤
  | Seoul Bike     | 8,760   | 12（不含     | 0     | 0.5 | 可用，但線性回 |
  |                |         | Date）       |       | 34  | 歸效果差       |

└────────────────────────┴─────────────┴──────────────────────┴─────────┴─────────┴
──────────────────────┘


  flood.csv 不適合的原因：測試集的 R² 是 1.000000，RMSE 是 0，代表目標值完全是
  20 個特徵的線性公式算出來的。這樣預測區間會是零寬度，特徵選擇也看不出差別，報
  告會很空洞。

  最後推薦

  - 題目 A：Flood Prediction，用 Playground S4E5 的 train.csv
    - 20 個數值特徵，R² 約 0.845，有實際的誤差，信賴區間和預測區間才畫得出意義。
    - 可以提交到 Kaggle 拿名次，對應評分裡「Kaggle 名次」那
      10%。提交前要先在競賽頁面按 Join Competition。
    - 檔案有 56 MB，網頁版要另外抽樣約 2 萬筆，才放得進 GitHub
      給瀏覽器讀；Python 主程式還是用全部資料訓練。
  - 題目 B：Student Performance Factors
    - 19
      個特徵，混合數值和類別，有少量缺失值。剛好能示範編碼和缺失值處理，和題目 A
      形成對比。
    - 檔案只有 0.6 MB，網頁可以直接讀。
以上述資料來源評估是否能完成
  - 走完 CRISP-DM 六個階段
  - 特徵選擇
  - 模型評估
  - 預測圖，要畫出信賴區間或預測區間
```

> 與
>
> - 加分 1 分：用下拉選單切換顯示兩個題目。
>   - 加分 2 分：可以輸入任意資料集網址，例如 50_Startups.csv (https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv)。
>
> 要求

ChatGPT

資料集是否符合機器學習期末專題要求？

依照你提供的資料集資訊，**可以完成 CRISP-DM 六個階段、特徵選擇、模型評估、預測區間，以及兩個題目的下拉選單切換。** 至於「輸入任意資料集網址」的加分項目，也可以實作，但必須限制支援的資料格式與預測任務，不能保證所有 CSV 都能直接套用。

我會建議採用 **題目 A：Flood Prediction 作為主要題目，題目 B：Student Performance Factors 作為第二個題目**。這樣既能展示完整的迴歸分析，也能比較數值特徵與混合型特徵的處理方式。

一、逐項評估需求可行性

以下是依照你提供的資料集描述進行的可行性評估，尚未實際執行完整程式驗證。

專題要求	可行性	評估與實作方式
CRISP-DM 六階段	可完成	以資料理解、資料準備、建模、評估、部署等流程建立完整分析頁面
特徵選擇	可完成	相關係數、Permutation Importance、RFE 等方法
模型評估	可完成	R^2、RMSE、MAE，並比較不同模型
預測圖	可完成	實際值與預測值散佈圖、殘差圖、預測區間圖
信賴區間／預測區間	可完成	使用統計模型或 Bootstrap 等方法估計
下拉選單切換兩個題目	可完成	共用分析介面，切換資料集後重新執行分析
輸入任意資料集網址	有條件可完成	支援可公開存取的 CSV，並要求使用者指定目標欄位及任務類型

注意：CRISP-DM 通常分為六個階段，除了資料理解、資料準備、建模、評估，還包含**商業理解**與**部署**。如果只是列出六個標題，說服力會不足；建議每個階段都顯示實際產出。

二、兩個資料集的適用性比較

題目 A：Flood Prediction

推薦作為主題

- 資料量：你提供的資訊為約 56 MB。
- 特徵：20 個數值特徵。
- 優點：適合展示迴歸模型、特徵重要性、模型比較與預測區間。
- 注意：資料量較大，網頁端宜使用抽樣資料繪圖；完整訓練可在 Python 後端或離線環境執行。

題目 B：Student Performance Factors

推薦作為比較題目

- 資料量：約 6,607 筆，約 0.6 MB。
- 特徵：19 個數值與類別混合的特徵。
- 優點：可展示缺失值處理、類別編碼，以及不同特徵的影響。
- 注意：必須確認目標欄位，例如考試成績或 Performance Index，並排除目標洩漏欄位。

為什麼不優先選擇 flood.csv？

依照你提供的測試結果，該資料集的 R^2=1.0、RMSE =0，代表目前測試流程下模型能完全預測目標值。

但這**不一定代表所有預測區間都會是零寬度**，也不能單憑這兩個數值斷定資料本身毫無研究價值。還需要檢查目標欄位是否由特徵直接計算、是否存在資料洩漏，以及訓練集與測試集的切分方式。

若確認目標值確實由特徵的線性公式直接產生，選擇具有實際預測誤差的資料集，通常更適合你的專題。

三、預測區間與信賴區間，如何真正做出來？

這是整個專題最需要注意的地方。

1. 信賴區間（Confidence Interval）

估計的是模型預測的平均反應值的不確定性。例如，特定條件下學生的平均預期成績。

2. 預測區間（Prediction Interval）

估計的是單一新樣本可能落在哪個範圍。由於包含個別樣本本身的變異，通常比信賴區間寬。

我建議採用以下實作方式：

模型	區間估計方式	適用性
Linear Regression	OLS 統計推論	可直接展示信賴區間與預測區間
Random Forest	Bootstrap 或 Conformal Prediction	可處理非線性關係
Gradient Boosting	Conformal Prediction	適合比較不同模型的區間表現

建議在圖表中呈現：

- 實際值與預測值的散佈圖。

- 預測值及其 95% 預測區間。
- 測試資料的區間涵蓋率（Coverage）。
- 平均區間寬度（Mean Interval Width）。

如此就不只是畫出一條預測線，而是能用數據評估區間是否可靠。

四、加分項目評估

加分 1：下拉選單切換兩個題目

介面示意：切換資料集後，更新對應的分析內容。

選擇分析題目

▾ 題目 A：Flood Prediction ／ 題目 B：Student Performance Factors

Flood Prediction

數值特徵迴歸分析、特徵重要性、模型評估與預測區間。

資料準備：需考量大檔案載入與抽樣繪圖。

此處為介面互動示意，不代表已載入真實資料或執行模型。

實作難度：低至中。 建議把資料處理、模型訓練、圖表和評估封裝成共用模組，切換資料集時只更換設定與資料，不要複製兩套程式。

加分 2：輸入任意資料集網址

以你提供的 `50_Startups.csv` 為例，這個資料集有數值欄位及類別欄位，適合用來展示通用迴歸分析。

建議支援以下流程：

1. 輸入公開 CSV 網址。
2. 載入資料並顯示前幾筆資料。
3. 自動判斷數值與類別欄位。
4. 由使用者選擇目標欄位。
5. 自動執行前處理、特徵選擇及模型評估。
6. 顯示預測圖、預測區間與評估指標。

不過，必須處理幾項限制：

- **CORS：** 某些 GitHub 原始資料網址可能因伺服器跨來源政策而無法由瀏覽器直接讀取。
- **任務類型：** 迴歸和分類需要不同的模型、評估指標與區間估計方式。
- **目標欄位：** 不同 CSV 的預測目標不一定相同，最好讓使用者自行指定。
- **資料品質：** 需要處理空值、文字欄位、常數欄位及不適合建模的欄位。
- **安全性：** 限制可接受的網址協定及檔案大小，避免任意網址載入造成安全風險。

因此，建議把加分功能定義為「支援符合格式與欄位條件的公開 CSV」，而非宣稱能分析任何資料集。

五、建議的最終專題架構

資料集選擇

Flood Prediction／Student Performance／自訂 CSV

↓

CRISP-DM 流程

商業理解 → 資料理解 → 資料準備 → 建模 → 評估 → 部署

↓

模型實驗

特徵選擇、模型比較、交叉驗證、超參數調整

↓

視覺化與評估

R^2／RMSE／MAE、特徵重要性、預測區間、涵蓋率

技術方面，如果你想使用 Python 建模，建議以 `pandas`、`scikit-learn`、`statsmodels`、`MAPIE`（預測區間）搭配 `Plotly` 或 `Matplotlib`。如果需要網頁介面，可以選擇 Streamlit；若課程要求前後端分離，則可以用 Vue 前端搭配 Python API。

最後結論

這兩個資料集可以支援你列出的主要功能，也適合做成有比較、有視覺化的完整專題。 我會優先確保以下三項：

1. 六個 CRISP-DM 階段都有實際分析內容。
2. 預測區間有明確的統計或機器學習方法，而不是只畫出上下界。
3. 下拉選單與自訂 CSV 共用同一套分析流程，避免程式重複且難以維護。

最後還有一點：若老師對「信賴區間或預測區間」沒有指定方法，建議兩種都實作在線性迴歸模型上，再用 Conformal Prediction 為非線性模型補上預測區間，這樣報告的理論與實驗會更完整。

使用者

> 完成的網頁如下 請進行功能與數據等驗證
> [https://hobartxiii.github.io/HW2-Multiple-Linear-regression/?problem=flood#overview]
> (https://hobartxiii.github.io/HW2-Multiple-Linear-regression/?problem=flood#overview)

ChatGPT

我已開啟你部署的網頁，並檢查了目前公開頁面可讀取的內容。網站名稱是「多元線性回歸分析」，包含洪水機率、學生考試成績與自訂資料集三種入口，並提供資料總覽、模型結果、評估、預測四個主要區段。

先說明驗證範圍： 目前我能確認公開頁面載入成功、介面所宣告的功能與分析流程，但僅靠頁面文字還不能證明 JavaScript 模型運算、實際數值、圖表及互動都正確。我會把「已確認的內容」和「需要進一步驗證的項目」分開，避免把功能說明誤當成實測結果。

一、目前網站的初步檢查

檢查項目	初步結果
GitHub Pages 網站可開啟	通過
`?problem=flood#overview` 網址可載入	通過
三種資料集入口	頁面已呈現
資料處理說明	頁面已呈現
80/20 切分、seed 42、5-fold CV	尚待實際計算驗證
特徵選擇、模型評估及區間估計	尚待數值驗證
自訂 CSV 網址與檔案上傳	尚待互動測試

網頁目前宣告的處理流程包含：訓練集補值與標準化、以 5-fold 交叉驗證比較方法、OLS 估計係數，以及區分信賴區間和預測區間。這些設計方向合理，但仍需要實際運算結果來證明。

二、數據驗證：最重要的檢查結果

我也查閱了你 GitHub 專案中的 README，當中記載了 Notebook 的實驗結果，以及網頁和 Notebook 之間的資料差異。這讓我們可以進一步核對數值是否有合理的依據。

1. Notebook 的實驗數據

以下是專案文件中記載的結果，**是文件報告值，並非我已在你的線上網頁重新執行所得的結果**。

評估項目	Flood Prediction	Student Performance
測試集 R^2	0.845	0.764
測試集 RMSE	0.020	1.83 分
95% 預測區間實際涵蓋率	94.6%	99.5%
特徵選擇結果	20 個特徵	27 個編碼後特徵中保留 21 個

資料來源：專案 README 所記錄的 Notebook 結果。

這些數值初步看起來合理，但有幾個地方需要特別說明：

- **Flood 的 $R^2 = 0.845$：** 代表模型在該測試集上解釋了約 84.5% 的目標變異，不代表預測正確率是 84.5%。
- **Student 的 $R^2 = 0.764$：** 表示模型對考試成績有一定的解釋能力，但仍有未被模型捕捉的變異。
- **Flood 的 94.6% 涵蓋率：** 與名目 95% 接近，是正面的初步結果，但仍應檢查涵蓋率的計算是否使用未參與模型選擇的測試資料。
- **Student 的 99.5% 涵蓋率：** 不代表模型一定更好。若預測區間過寬，即使涵蓋率很高，實用價值仍可能有限。因此應同時呈現平均區間寬度。

2. 網頁和 Notebook 的數據不能直接要求完全一致

你的 README 已說明，網頁使用的是 Flood 資料集的 20,000 筆抽樣，而且使用另一個隨機切分，因此數值可能與 Notebook 不同。

這是可以接受的設計，但報告應明確標示兩者的資料範圍與切分方式。

建議至少顯示：

- 資料集筆數及抽樣方式。
- 訓練集與測試集筆數。
- 隨機種子與切分比例。
- 交叉驗證方式。

- 模型名稱及所選特徵數。

這樣老師才不會把合理的數值差異誤判成程式錯誤。

三、程式碼層級的數學與統計檢查

我進一步查看了網頁的 `mlr.js` 、 `app.js` 和 `compare_statsmodels.py` 。這比只看畫面更有價值，因為可以檢查模型實際採用的公式、資料切分和驗證方式。

1. 已確認有實作的功能

功能	程式碼檢查結果
缺失值處理	有以訓練集的中位數／眾數補值
類別編碼	有 One-hot Encoding，並排除第一個類別
標準化	使用訓練集平均數及標準差
資料切分	有 seed 42 的隨機 80/20 切分
特徵選擇	有 SelectKBest、RFE、Sequential Forward
OLS 係數與標準誤	有實作
信賴區間、預測區間	有依 OLS 公式計算
測試集評估	有 MAE、MSE、RMSE、R^2
新資料預測	有根據使用者輸入即時重新預測

以上均可從公開程式碼中找到對應實作。

2. 發現的統計方法問題

以下是我認為值得優先處理的項目。

高優先度 **問題一：交叉驗證的特徵選擇可能有資料洩漏**

在 `mlr.js` 中，`rankKBest()` 和 `rankRFE()` 先使用整個訓練集計算特徵排序，再使用這個排序計算 5-fold CV RMSE。

這代表每個驗證折的目標值，可能已間接影響該折所使用的特徵排序，使 CV RMSE 偏樂觀。

建議： 每一折都只用該折的子訓練資料重新執行特徵選擇、補值與標準化，再評估驗證折。最終測試集則保留到所有模型選擇完成後才使用。

高優先度 **問題二：Durbin–Watson 獨立性檢定的解讀不恰當**

程式以殘差相鄰差值計算 Durbin–Watson 統計量。

但你的資料是隨機切分的橫斷面資料，觀測值排列順序不一定有時間或空間意義。此時直接將 DW 介於 1.5 至 2.5 判定為通過，容易造成誤解。

建議： 改為「殘差獨立性需依資料結構判斷」，並說明 DW 只有在觀測順序有意義、且符合適用條件時才值得解讀。

中優先度 **問題三：特徵選擇後的信賴區間未反映選擇的不確定性**

目前係數的標準誤及區間是根據選定模型的 OLS 公式計算。

這些公式可用於一般 OLS 推論，但先從同一份訓練資料選出特徵，再將特徵視為事先確定，可能低估完整建模流程的不確定性。

建議： 在報告中明確說明，係數區間是「選定模型條件下」的傳統 OLS 區間；若要推論特徵選擇後的區間，需另外採用適合的方法。

3. 其他應注意的細節

- **測試集 PI 覆蓋率：** 程式確實計算測試樣本落在預測區間內的比例；但覆蓋率接近 95% 不能單獨證明區間具有良好的校準性，還要檢查區間寬度及不同樣本區段的表現。
- **線性假設檢查：** 殘差圖是視覺診斷，不能只用一個統計門檻就宣稱所有假設成立。
- **數值驗證測試：** `compare_statsmodels.py` 確實建立了與 statsmodels 比較係數、標準誤、p 值、CI、PI、R^2 等結果的測試流程；但程式碼存在不代表該測試已在目前部署版本成功執行。
- **驗證精度說明：** README 宣稱誤差小於 10^{-12}，但測試程式中的通過門檻是 10^{-6} 或 10^{-5}。這兩者並不等價，建議改成實際測得的最大誤差，而非只報宣稱的精度。

四、功能驗收清單

下列項目需要在瀏覽器中實際操作才能判定是否通過。我目前沒有能夠完整操作你的網頁 DOM、擷取所有執行時結果及瀏覽器 Console 的環境，因此不會把這些項目標示為已實測成功。

手動驗收表

0 / 14 項已勾選

資料集與路由

- ☐ 直接開啟 ?problem=flood 可載入洪水資料
- ☐ 切換 Student 後資料、目標欄位和圖表同步更新
- ☐ 重新整理或使用 ?problem=student 直接進入學生題目
- ☐ 切換自訂資料集後，舊資料與舊圖表不會殘留

模型與統計

- ☐ 變更目標欄位後模型重新訓練
- ☐ 取消所有特徵時出現提示而不是崩潰
- ☐ 變更特徵選擇方法、k、信心水準後結果更新
- ☐ CI 包含預測平均值，PI 包含 CI 且通常更寬
- ☐ 實際值、預測值、殘差與評估指標使用相同測試集

自訂資料集與穩定性

- ☐ 成功讀取指定的 50_Startups.csv
- ☐ 成功上傳本機 CSV
- ☐ 遇到 CORS、無效網址、空檔案或只有一欄時顯示錯誤
- ☐ 有缺失值、未知類別或常數欄位時不會產生 NaN 污染
- ☐ 快速連續切換題目時，較早的請求不會覆蓋新資料

五、CRISP-DM 要求是否完整？

這裡還有一個容易被老師注意到的地方。

目前網頁側邊欄只列出四個區段：Data Understanding、Modeling、Evaluation、Deployment。

但 CRISP-DM 正式流程有六個階段：

✓

1. 商業理解（Business Understanding）

README 有說明研究目標，但網頁最好新增明確區段，描述預測目的、使用情境及限制。

✓

2. 資料理解（Data Understanding）

已有資料表、敘述統計、欄位檢查與相關係數。

✓

3. 資料準備（Data Preparation）

已有前處理邏輯，但建議把缺失值、編碼、標準化、切分和排除欄位的結果獨立呈現。

✓

4. 建模（Modeling）

已有特徵選擇、係數與模型比較。

✓

5. 評估（Evaluation）

已有測試集指標、預測圖、殘差及假設檢查；應修正上述統計解讀問題。

✓

6. 部署（Deployment）

已有互動式預測功能。可再補充模型適用範圍、使用限制與重新訓練方式。

這不表示你沒有完成六個階段的分析內容，而是**網頁目前的導覽沒有明確展示完整六階段**。如果老師依照 CRISP-DM 評分，我建議優先調整這一點。

六、最終驗證結論

整體判定

✓

架構與功能設計：基本完整

公開頁面、程式模組、主要建模功能及統計測試程式均可查閱。

⚠

統計方法：建議修正

優先處理交叉驗證特徵選擇洩漏、Durbin–Watson 的解讀，以及 CI/PI 的適用限制。

•

實際執行數值與互動：尚未完全驗收

需要執行瀏覽器測試與數值對照，才能確認部署版本的所有功能都正常。

我最建議你先修正**交叉驗證中的特徵選擇資料洩漏**，因為它會影響模型比較的可信度；其次是調整 CRISP-DM 六階段的呈現，以及獨立性檢查的說明。

如果你能再提供 `web/` 資料夾的 ZIP，或讓我取得瀏覽器實際執行結果，我就能繼續針對程式進行更完整的驗證，包括逐項數值比對、測試案例結果及需要修改的具體程式碼。

使用者

> 有其他的csv 驗證資料即可以進行測試嗎？請提供我網址

ChatGPT

可以！針對你目前的「多元線性回歸分析」網頁，我建議使用以下 CSV 進行**外部資料集驗證**，特別測試數值特徵、類別特徵、缺失值、非線性關係及預測區間。

以下網址以公開資料來源為主。我優先挑選能直接取得 CSV 的連結，方便你貼到網頁的「自訂資料集」功能測試。

一、推薦的 CSV 測試網址

1. Concrete Compressive Strength

最推薦

1,030 筆資料｜8 個數值特徵｜連續型目標

測試混凝土配方與抗壓強度的關係。UCI 說明此資料具有非線性關係，適合檢查線性模型的預測能力及殘差診斷。

CSV 直接網址：

此資料集官方提供的是 Excel 檔，以下連結為 GitHub 上的 CSV 版本：

Concrete_Data.csv（https://raw.githubusercontent.com/selva86/datasets/master/Concrete_Data.csv）

建議目標欄位：`strength`（請以實際 CSV 標題為準）。

2. Wine Quality（紅酒品質）

1,599 筆資料｜11 個數值特徵｜品質評分

這是 UCI 經典資料集，可測試多個數值特徵、特徵選擇及預測區間。目標欄位為 `quality`。

CSV 直接網址：

winequality-red.csv（https://archive.ics.uci.edu/ml/machine-learning-databases/wine-quality/winequality-red.csv）

注意：此 CSV 使用分號（`;`）分隔欄位。若你的程式只支援逗號，可能會被誤讀成單一欄位，正好可以測試分隔符號處理能力。

3. Auto MPG

398 筆資料｜數值與類別型特徵｜含缺失值

用汽車排氣量、重量、年份等資訊預測每加侖行駛英里數（MPG）。原始資料包含缺失的 horsepower 值及類別資訊，適合測試前處理。

CSV 直接網址：

Auto MPG CSV（https://raw.githubusercontent.com/mwaskom/seaborn-data/master/mpg.csv）

建議目標欄位：`mpg`。

可檢查缺失值補值、類別編碼，以及非數值欄位的排除或轉換。

4. Boston Housing

506 筆資料｜多個數值特徵｜房價預測

經典房價迴歸資料，可測試 R^2、RMSE、MAE、特徵選擇及預測區間。

CSV 直接網址：

BostonHousing.csv（https://raw.githubusercontent.com/selva86/datasets/master/BostonHousing.csv）

建議目標欄位：`medv`。

提醒：Boston Housing 有已知的資料倫理與代表性爭議，建議僅作為技術驗證資料，不宜直接作為現代房價決策依據。

二、如何用這些資料測試你的網頁？

我建議依照下列順序進行，每一份資料都記錄是否成功載入、目標欄位、實際筆數、R^2、RMSE、MAE，以及預測區間涵蓋率。

測試順序	資料集	主要驗證目的
1	Concrete	一般數值迴歸與非線性資料
2	Boston Housing	基本迴歸指標及特徵選擇
3	Auto MPG	缺失值、類別編碼
4	Wine Quality	分號分隔、品質預測與區間

三、建議額外測試的異常情況

除了正常資料，你還應該測試：

- 輸入不存在的網址。
- 輸入非 CSV 網址，例如 PDF。
- CSV 只有一個欄位。
- 目標欄位包含空值。
- 特徵全部是常數。
- CSV 包含文字欄位或缺失值。
- 選擇與目標欄位相同的欄位作為特徵。

這些測試有助於確認網頁不只在理想情況下能運作，也能正確處理錯誤並顯示清楚的提示。

我的建議：先用 Concrete、Auto MPG 和 Wine Quality 這三份資料。 它們分別能測試數值迴歸、缺失值與類別欄位、分隔符號問題，比只用另一份乾淨的數值 CSV 更能驗證你的網頁是否真的具有通用資料集分析能力。

二、Claude Code 對話

姓名 邱勇嘉 • 學號 5115056022 • AI 工具：Claude Code（Anthropic，Claude Opus 5.5）• 對話期間 2026-10-17 至 10-18
節錄 20 則使用者訊息及 Claude 的回覆。完整程式碼見 notebook 與 GitHub repo。

使用者

> 讀取 HW2 裡面的 readme.html

Claude

我讀完了 HW2/readme.html，以下是內容整理：

HW2：多元線性回歸（Multiple Linear Regression）

作業目標：延伸 HW1，用真實資料集做多元線性回歸，並照 CRISP-DM
流程完成整個分析。

作業內容

1. 資料來源：到 Kaggle 選一個公開資料集，要有 10–20
   個特徵，題材不限。要寫明資料集來源和連結。
2. 分析任務
   - 用線性回歸做預測，可以是單純線性回歸、多元線性回歸或 Auto Regression。
   - 一定要做特徵選擇（Feature Selection）和模型評估（Model Evaluation）。
   - 結果要附預測圖，並畫出信賴區間或預測區間。
3. CRISP-DM 六個階段：Business Understanding → Data Understanding → Data
   Preparation → Modeling → Evaluation → Deployment。
4. AI 協助要求
   - 和 ChatGPT 的對話要匯出成 PDF（可用 pdfCrowd 等工具）。
   - 要用 NotebookLM 研究網路上同主題的解法，寫一份 100 字以上的摘要放進報告。
   - 報告裡要清楚標出「GPT 輔助內容」和「NotebookLM 摘要」。
5. 繳交內容
   - 主程式：7114056XXX_hw2.py 或 .ipynb
   - 報告（PDF）要包含：CRISP-DM 分析流程、GPT 對話紀錄、NotebookLM
     摘要、和網路上主流或更好的解法做比較。
   - 全部檔案壓成一個以學號命名的 zip，例如 7114056XXX_hw2.zip。
   - （選做）如果放 GitHub 或用 Colab 寫，要附連結，並在 README.md
     整理流程與成果。

評分標準

項目	比重
CRISP-DM 流程完整、邏輯清楚	25%
包含 GPT 對話和 NotebookLM 摘要	15%
資料集來源和研究脈絡說明清楚	10%
模型能正確執行，有做特徵選擇和評估	25%
結果合理、美觀、有說服力	15%
Kaggle 名次（如果有）、預測圖、評估指標	10%

補充（老師貼的 ChatGPT 對話）

- 特徵數條件改成 14–39 個（> 13、< 40），和上面寫的 10–20 個不一樣。
- 推薦的資料集：
  a. Predict the Flood（20 個特徵，目標是 FloodProbability）← 首選，全部都是數值特徵，不用做類別編碼
  b. Flood Prediction（Playground S4E5，20 個特徵）
  c. Istanbul Apartment Prices 2026（約 29 個特徵，目標是 Price）
  d. Swiss Housing Price（30 個特徵，資料取用有限制）
  e. Human–AI Interaction（20 個特徵，合成資料）
  f. House Prices – Advanced Regression（79 個特徵，需要先篩到 20–30 個）
- 建議做法
  - 模型比較 LinearRegression、Ridge、Lasso。
  - 評估看 MAE、MSE、RMSE、R^2、Adjusted R^2，並檢查五大回歸假設。
  - 特徵選擇比較 SelectKBest、RFE、Sequential Feature Selection、Lasso、permutation importance，分別選 14、20、25 或 30 個特徵，而且只能用訓練資料來選。
- 額外說明
  - 兩個題目都要做，但只上傳其中一個；第二個可以直接套用 skill 或 workflow。
  - 範例成果網站：https://huanchen1107.github.io/AIoT-DIC2-MultipleLR/
  - 加分 1 分：用下拉選單切換顯示兩個題目。
  - 加分 2 分：可以輸入任意資料集網址，例如 50_Startups.csv (https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv)。
  - 另外附有部署到 GitHub Pages 的步驟：在 Settings → Pages 的 Source 選 GitHub Actions，或選 main 分支的 / (root)。

需要的話，我可以接著幫你挑資料集或開始寫程式。

使用者

> 以「二、作業內容」為準

Claude

好，之後以「二、作業內容」為準：Kaggle 資料集的原始特徵數要在 10–20 個之間。補充裡寫的 14–39 個不算。我也記下來了，之後的對話會沿用這個標準。

用這個條件重看補充裡推薦的資料集（特徵數是照補充裡的描述，還沒實際打開 CSV 確認）：

資料集	特徵數	是否符合 10–20 個
Predict the Flood	20	✅ 符合
Flood Prediction（Playground S4E5）	20	✅ 符合
Human–AI Interaction	20	✅ 符合，但是合成資料
Istanbul Apartment Prices	約 29	❌ 超過
Swiss Housing Price	30	❌ 超過，取用也有限制
House Prices – Advanced	79	❌ 超過

建議用 Predict the Flood 或 Flood Prediction（Playground S4E5）。 兩個都是 20 個數值特徵，不用做類別編碼，目標也是連續值，很適合做特徵選擇、算評估指標、畫預測區間。

依「作業內容」，必做的項目是：
- 走完 CRISP-DM 六個階段
- 特徵選擇
- 模型評估
- 預測圖，要畫出信賴區間或預測區間
- ChatGPT 對話匯出成 PDF
- NotebookLM 摘要（100 字以上）
- 和網路上主流或更好的解法做比較
- 所有檔案壓成以學號命名的 zip

補充裡的下拉選單、任意輸入資料集網址、GitHub Pages 部署，我會當成選做的加分項。

要我用 Flood 資料集開始寫 hw2.py 或 .ipynb 嗎？

使用者

> 有辦法先上 Kaggle，配合加分項目先挑選資料集嗎？

Claude

可以先挑資料集，但我還沒有進到 Kaggle 頁面本身。這台電腦沒有裝 Kaggle CLI，也沒有登入憑證，所以這次是用網路搜尋查第三方鏡像和 UCI 的說明，特徵數還要到 Kaggle 頁面確認。

挑選條件

- 作業本身：原始特徵 10–20 個，目標是連續值。
- 下拉選單加分：要選兩個題材不同的資料集，切換時才看得出差別。
- 輸入任意資料集加分：網頁要能直接用網址讀 CSV。Kaggle 下載要登入，所以資料集的 CSV 要另外放在 GitHub repo，用 raw 網址讀取。檔案不能太大，瀏覽器才跑得動。

候選資料集

資料集	特徵數	筆數	優點	注意
Flood Prediction（50k 版本）	約 20，全部是數值	5 萬	不用編碼，線性關係明顯，很適合畫預測區間	合成資料；只是「約 20」，要確認正好是 20 才符合
Flood（Playground S4E5）	20	約 112 萬	同上	檔案太大，網頁跑不動，不建議
Student Performance Factors	19（數值和類別混合）	6,607	能示範類別編碼和特徵選擇，主題好懂	合成資料
Seoul				目標是租借數，非線

Bike Sharing Demand	約 13	8,7 60	真實資料	性很強，線性回歸的 R^2 會偏低
Life Expectancy (WHO)	約 20	2,9 38	真實資料，說服力高	有缺失值；Country 欄要排除，否則超過 20 個

我的建議組合

- 題目 A：Flood Prediction（50k 版本）。數值特徵、乾淨，最容易做出好看的結果和預測區間。
- 題目 B：Student Performance Factors。類別混合數值，剛好和 A 形成對比：一個不用前處理，一個要做編碼。

如果你比較在意「真實資料」，可以把 B 換成 Life Expectancy (WHO)，報告會更有說服力，但要多處理缺失值。

下一步

要我用 Chrome 打開這幾個 Kaggle 頁面，確認實際欄位和下載方式嗎？下載需要你的 Kaggle 已經在 Chrome 登入。或者你直接告訴我選哪兩個。

Sources:
- Student Performance Factors（Baselight 鏡像） (https://baselight.app/u/kaggle/dataset/lainguyn123_student_performance_factors)
- Students Performance Factors（Mendeley） (https://data.mendeley.com/datasets/g94zzvpkk7/1)
- Life Expectancy (WHO) 更新版（Baselight） (https://baselight.app/u/kaggle/dataset/lashagoch_life_expectancy_who_updated/table/life_expectancy_data_updated)
- Life expectancy 迴歸說明（Isalos） (https://www.docs.isalos.novamechanics.com/files\Regression\Life%20expectancy\life_expectancy.pdf)
- Seoul Bike Sharing Demand（UCI） (https://archive.ics.uci.edu/dataset/560)
- Seoul Bike Sharing Demand（UCI archive-beta） (https://archive-beta.ics.uci.edu/dataset/560/seoul+bike+sharing+demand)
- Flood Prediction Dataset（Baselight 鏡像） (https://baselight.app/u/kaggle/dataset/aritra100_flood_prediction_dataset)

使用者

> 已安裝 Kaggle CLI 並登入

Claude

收到，CLI 已經可以使用，四個資料集也已下載。接下來安裝分析需要的套件，作業本身也會用到。

Claude

四個候選資料集都下載下來檢查過了。結論是 Flood 原本推薦的 50k 版本不能用，要改用 Playground 競賽版。

檢查結果

資料放在 D:\AIoTAI\HW2\data\。下表的 R^2 是基準值：所有特徵直接丟進線性回歸，用 80/20 切分在測試集上算出來的。

資料集	筆數	特徵數	缺失值	基準 R^2	判斷
Flood flood.csv（50k 版本）	50,000	20，全數值	0	1.000	❌ 不適合
Flood train.csv（Playground S4E5）	1,117,957	20，全數值	0	0.845	✅
Student Performance Factors	6,607	19，數值和類別混合	235 格	0.770	✅
Life Expectancy (WHO)	2,938	20（不含 Country）	2,563 格	0.571	可用，但前處理比較多
Seoul Bike	8,760	12（不含 Date）	0	0.534	可用，但線性回歸效果差

flood.csv 不適合的原因：測試集的 R^2 是 1.000000，RMSE 是 0，代表目標值完全是 20 個特徵的線性公式算出來的。這樣預測區間會是零寬度，特徵選擇也看不出差別，報告會很空洞。

最後推薦

- 題目 A：Flood Prediction，用 Playground S4E5 的 train.csv
  - 20 個數值特徵，R^2 約 0.845，有實際的誤差，信賴區間和預測區間才畫得出意義。
  - 可以提交到 Kaggle 拿名次，對應評分裡「Kaggle 名次」那 10%。提交前要先在競賽頁面按 Join Competition。
  - 檔案有 56 MB，網頁版要另外抽樣約 2 萬筆，才放得進 GitHub 給瀏覽器讀；Python 主程式還是用全部資料訓練。
- 題目 B：Student Performance Factors
  - 19 個特徵，混合數值和類別，有少量缺失值。剛好能示範編碼和缺失值處理，和題目 A 形成對比。
  - 檔案只有 0.6 MB，網頁可以直接讀。

有一件事要你決定：題目 A 要不要提交 Kaggle 拿名次？要的話，請先到 https://www.kaggle.com/competitions/playground-series-s4e5 按 Join Competition。我再用 CLI 下載官方的 test 檔，產生 submission 並提交。

另外，為了跑這次檢查，我裝了 scikit-learn 和 statsmodels，作業本身也會用到。

使用者

> 好，開始做 Python notebook

Claude

所需套件（matplotlib、seaborn、nbconvert）已安裝完成，也確認了 HW1 的慣例。接下來開始寫 HW2/hw2.ipynb：先用產生器腳本建立 notebook 格子，再實際執行確認可運行。

Claude

notebook 正在執行。百萬筆的 Flood
資料加上特徵選擇需要幾分鐘，跑完我會檢查結果。

Claude

sklearn 1.9 的 LassoCV 已經拿掉 n_alphas 參數，改成用 alphas。修正後重新執行：

Claude

正在重新執行，跑完我會檢查各格子的輸出。

Claude

執行成功。我在跑之前就先寫好了結論文字，現在要逐一核對它們和實際輸出是否相符。

Claude

發現三處需修正：題目B的實際覆蓋率是99.5%而非預期的95%、精簡模型MAE（0.54）明顯差於全特徵模型（0.45）、以及有一筆分數101分超過滿分。接下來我會核對其餘數字並檢查圖表。

Claude

圖表和數字都核對完畢，另外發現兩個值得記入報告的點：題目A中20個係數幾乎等於0.00565，顯示洪水機率近似線性加總所有特徵，解釋了特徵選擇無法刪減的原因；題目B中98%測試殘差落在±1.3分內，誤差集中在約0.5%的高分離群學生，說明了預測區間覆蓋率偏高的原因。接下來我會把這些發現寫進markdown，並修正與實際結果不符的部分。

Claude

markdown 已修正完，所有數字都對照過實際輸出。正在做最後一次執行。

Claude

結果沒錯，但 flood_model.joblib 有 837MB，因為 statsmodels 的結果物件把近 90 萬筆訓練資料也存進去了，這會讓繳交的 zip 爆掉。我接下來會在存檔前用 remove_data() 把這些資料移除。

Claude

remove_data() 拿掉資料後，預測和區間的結果完全不變，所以不需要剛才那種繞路寫法。改成直接呼叫：

Claude

正在重新執行，確認模型檔變小、預測結果不變。

Claude

我把 HW2/hw2.ipynb
做好了，也從頭到尾完整跑過一次，沒有任何錯誤。全部檔案都放在 HW2 底下，其他資料夾沒有動。

主要結果

	題目 A：Flood（Playground S4E5）	題目 B：Student Performance
原始特徵數	20	19
特徵選擇	20 個全部保留	27 個編碼欄位保留 21 個
測試集 R^2 / RMSE	0.845 / 0.020	0.764 / 1.83 分
95%	94.6%	99.5%

預測區間的實際覆蓋率		

notebook 內容

- 兩個題目都依 CRISP-DM 六個步驟寫，說明文字是繁體中文。
- 特徵選擇比較 5 種方法：SelectKBest、RFE、Sequential Forward、Lasso path、Permutation importance。都只用訓練資料，並畫出 CV RMSE 隨特徵數 k 變化的曲線。
- 模型比較 OLS（全部特徵、選出的特徵）、Ridge、Lasso，指標包含 MAE、MSE、RMSE、R^2、Adj R^2 和 CV。
- 預測圖畫出 95% 信賴區間和預測區間，另外檢查回歸的五大假設：殘差圖、Q-Q 圖、Durbin-Watson、Breusch-Pagan、Jarque-Bera、VIF。
- Deployment：存成模型檔，並示範對新資料預測，同時輸出 CI/PI。

執行後修正的地方

- 我在執行前就先寫好了結論文字，跑完逐一核對，有三處和實際結果不符，已經改成實際數字：
  - 題目 B 的預測區間覆蓋率實際是 99.5%，不是「接近 95%」。原因是約 0.5% 的高分離群學生把殘差撐大，區間因此偏寬。
  - 題目 B 的精簡模型 MAE 比全特徵模型高約 20%，不能說「幾乎相同」。這是選 k=21 的代價，報告裡有說明取捨。
  - 有 1 筆成績是 101 分，超過滿分，已在資料理解的段落註明。
- 新增的發現：題目 A 的 20 個係數都約 0.00565，等於洪水機率幾乎只取決於 20 項評分的總和。這可以用在報告的「主流解法比較」那段。
- 原本 Flood 的模型檔有 837 MB，因為 statsmodels 會把訓練資料一起存進去。拿掉資料後剩約 7 MB，預測結果完全不變。

產生的檔案

- outputs/flood_model.joblib（7 MB）
- outputs/student_model.joblib（58 KB）
- outputs/submission_flood.csv（20 MB），可以提交到 Kaggle 拿名次。

你需要做的事

1. 檔名：作業要求用學號命名，請把 hw2.ipynb 改成 你的學號_hw2.ipynb。
2. Kaggle 名次（選做）：到 https://www.kaggle.com/competitions/playground-series-s4e5 按 Join Competition，之後我可以幫你用 CLI 提交。
3. 壓縮繳交時：data/ 有 150 MB 左右，submission_flood.csv 也有 20 MB。建議 zip 裡不要放這兩個，notebook 開頭已經寫了資料的下載指令。

下一步可以做加分網頁，或者先處理 Kaggle 提交，你想先做哪個？

使用者

> Kaggle 提交

Claude

Kaggle 拒絕了這次提交，回傳 403 Forbidden。檔案已經上傳完，被擋在最後建立提交的那一步，最常見的原因是這個帳號還沒加入競賽。

請你這樣做：

1. 打開 https://www.kaggle.com/competitions/playground-series-s4e5
2. 按右上角的 Join Competition（也可能顯示為 Late Submission），再按 I

Understand and Accept 接受規則。
3. 如果帳號還沒做過手機驗證，Kaggle 可能會要求先驗證，提交競賽需要這一步。

做完告訴我，我會重新提交，再把分數和排行榜位置抓下來。

這個競賽已經結束，所以提交會算成 late submission，只會看到 Public/Private 分數，不會出現在正式排行榜上。我會拿分數去對照排行榜，換算出相當於第幾名，這樣就能放進報告。

使用者

> 已加入競賽，重新提交

Claude

提交成功，Kaggle 正在算分數。我在背景等它算完，順便下載排行榜，用來換算名次。

Claude

提交成功，Kaggle 已經算出分數。

分數與名次

項目	結果
Public Score（R^2）	0.84458
Private Score（R^2）	0.84426
換算 Public 排行榜名次	約 第 1,850 名 / 2,794 隊，大約在前 66%
第一名分數	0.86943
中位數分數	0.85856

- Kaggle 的分數和本機測試集 R^2（0.845）幾乎一樣，代表本機的評估結果可信。
- 名次是用你的分數對照下載的 Public 排行榜算出來的。競賽已經結束，late submission 不會真的出現在排行榜上。
- 排行榜存在 outputs/lb/ 底下的 csv。

報告裡可以這樣解讀名次

單純線性回歸只用 20 個原始特徵，和第一名差 0.025。前段班的做法是加入「特徵總和」、標準差、排序統計量等工程特徵，再用 GBDT 集成。這正好接上 notebook 裡的發現：係數全部約等於 0.00565，代表目標值主要由特徵總和決定。這段可以當作報告「網路主流解法比較」的素材。

建議補的兩件事

1. 截圖：到 https://www.kaggle.com/competitions/playground-series-s4e5/submissions 截一張提交紀錄放進報告，這是名次的佐證。
2. notebook：A-6 可以再加一小段「Kaggle 提交結果」，寫入上面的分數和換算名次。要我加嗎？

之後可以接著做加分網頁。

使用者

> 把 Kaggle 名次加進 notebook

Claude

Kaggle 的段落已經加進 A-5，正在重跑整個 notebook，大約 4 分鐘。跑完我會檢查名次圖和表格。

Claude

排行榜分數明顯分成兩群：約450隊落在0.8446附近（純線性回歸水準，正是你的分數），另有約660隊集中在0.869（加了特徵工程如「特徵總和」）。我把這點加進解讀文字，不需要重跑任何東西。

Claude

Kaggle 的名次已經加進 notebook，放在 A-5 Evaluation 的最後一段「Kaggle 提交結果與名次」，緊接在預測圖和評估指標後面，對應那一項 10% 的評分。整份 notebook 重新跑過，沒有錯誤。

新增的內容

1. 說明：提交日期、submission id 57316306、late submission 的意思，以及下載排行榜的指令。
2. R^2 對照表：

來源	R^2
本機測試集	0.84488
Kaggle Public	0.84458
Kaggle Private	0.84426
排行榜第 1 名	0.86943
排行榜中位數	0.85856

表格下面印出換算名次：1,850 / 2,794 隊。
3. 排行榜分數分佈圖：標出你的分數、中位數和第一名的位置。
4. 解讀：
   - 本機評估和 Kaggle 分數一致，代表模型沒有過擬合。
   - 排行榜分成兩群：約 450 隊在 0.8446，正好是你的位置，也就是純線性回歸的上限；約 660 隊在 0.869，是用了特徵總和等工程特徵的解法。這和 notebook 裡「係數都約 0.00565」的發現互相印證。

分數是在 notebook 裡直接寫成數字，因為 Kaggle 的分數只能透過登入後的 CLI 查詢。排行榜則是從 outputs/lb/ 讀進來，所以這個資料夾要跟著 notebook 一起放進 zip。

下一步要做加分網頁嗎？

使用者

> 好，開始做加分網頁

Claude

我會把網站放在 HW2/web/ 作為 GitHub Pages 根目錄，用純 HTML/JS 搭配 Chart.js 畫圖、PapaParse 讀 CSV，回歸運算在瀏覽器執行，並另寫獨立檔案用 Node 跑同份資料與 Python statsmodels 比對驗證。接下來先開始寫數學和統計函式。

Claude

接著寫運算流程的核心：前處理、資料切分、特徵選擇、OLS、區間和診斷。這部分不碰畫面，所以可以在 Node 裡單獨測試：

Claude

接著準備網頁要用的兩份資料，再寫測試，拿同一份資料的切分和編碼，和 statsmodels 的結果逐項比對：

Claude

四個案例的係數、標準誤、p 值、CI/PI、R^2，以及 DW、JB、BP、VIF 診斷都和 statsmodels 一致（誤差小於 1e-12），50_Startups 也正確選出 R&D Spend 和 Marketing Spend 兩個特徵，符合預期的 k=2。不過發現一個 bug：唯一值計算的上限設為 5,000，導致 Flood 資料的 id 欄（2 萬筆）未被正確排除而誤當成特徵，我接下來會修正這個問題。

Claude

修正後四個案例仍然全部和 statsmodels 一致，id 也正確排除了。運算核心完成，接著寫網頁介面。

Claude

接著寫介面邏輯 app.js：

Claude

介面寫好了，接著實際在瀏覽器測試。先在本機啟動網頁伺服器：

Claude

頁面運作正常，只是第一次載入時截圖逾時。重試一次：

Claude

連一般目錄頁的截圖都逾時，看來是瀏覽器視窗端的問題，而非頁面本身的 JavaScript 有誤。我改用 Edge 的 headless 模式在本機截圖試試看。

Claude

桌面版深淺色顯示正常，但手機版截圖右側被裁掉，可能是 headless 視窗限制或版面溢出造成的。我先修正 grid 欄位使用 minmax(0, 1fr) 這個潛在溢出問題，再用 390px 寬的 iframe 實測。

Claude

在390px手機寬度下，頁面scrollWidth正好是390，沒有橫向捲動問題，只有表格在自己的捲動框內左右滑動，確認版面正常，之前截圖裁切只是headless視窗最小寬度限制。現在來刪除測試用的暫存檔。

Claude

我把加分網頁做好了，放在 HW2/web/，兩個加分項都完成。目前還在本機執行，你可以打開 http://127.0.0.1:8765/ 自己操作看看。

加分項對應

加分項: 下拉選單切換兩個題目（+1）
做法: 「題目／資料集」選單可以切換 A：洪水機率、B：學生成績

加分項: 輸入任意資料集（+2）
做法: 選「自訂資料集」，貼上 CSV 網址，或上傳本機檔案。有一個按鈕能直接載入 50_Startups 範例。GitHub 一般網頁的網址會自動轉成 raw 連結。也可以用 ?url=... 的網址直接開啟某份資料

頁面內容

每次換資料或換設定，都會在瀏覽器裡重新訓練。頁面依 CRISP-DM 分成四段：

1. 資料：資料集說明、來源連結，以及每個欄位的類型、缺失值和用途。ID 欄、常數欄、類別太多的欄位（例如日期）會自動排除。
2. 設定：可以選預測目標、特徵選擇方法（自動、Forward、RFE、SelectKBest）、特徵

數 k，以及 90/95/99% 的信心水準。

3. 評估：
   - 指標卡片：R^2、Adj R^2、RMSE、MAE、PI 覆蓋率、CV RMSE
   - 預測圖：帶 CI 和 PI 色帶
   - 實際值對預測值圖、殘差圖
   - 特徵選擇曲線
   - 五大假設檢查表和係數表
4. 預測新資料：依特徵自動產生輸入表單，即時算出預測值和 CI/PI。

驗證結果

- 數值正確性：網頁的運算核心拿四個案例和 statsmodels 比對：Flood、Student 兩種方法、50_Startups。係數、標準誤、p 值、CI/PI、R^2、DW、JB、BP、VIF 全部一致，誤差在 1e-12 以下。測試可以重跑：在 HW2/web 執行 python tests/compare_statsmodels.py。
- 測試抓到並修好的 bug：Flood 的 id 欄原本沒被排除。
- 50_Startups：自動選出 R&D Spend 和 Marketing Spend，k=2，和老師範例網站的結論相同。
- 畫面：用 Edge headless 截圖檢查了深色、淺色和手機寬度 390px，沒有橫向捲動。Chrome 擴充功能的截圖連一般頁面都逾時，所以沒有用它測試。

要注意的地方

- 網頁的數字和 notebook 會略有不同，因為網頁用的是 Flood 抽樣的 2 萬筆，而且是另一次隨機切分。例如 Student 題目，網頁自動選了 Forward k=22、R^2 0.773；notebook 是 RFE k=21、R^2 0.764。報告請以 notebook 的數字為準，網頁當作互動展示。
- 自訂網址要允許跨網域讀取。GitHub raw 可以；Kaggle 的下載網址不行，因為需要登入。讀取失敗時，頁面會提示改用上傳。

下一步：部署到 GitHub Pages

這一步需要你決定：

1. 要開一個新的 GitHub repo 嗎？名稱要叫什麼，例如 AIoT-HW2-MultipleLR？
2. repo 裡只放 web/ 和 notebook 就好，還是整個 HW2 都放？我建議不要放 data/，有 150 MB。

決定後，我可以幫你建立 repo、推上去並開啟 Pages。推送到 GitHub 是公開動作，執行前我會先跟你確認。

使用者

> （以下網頁規格 prompt 是另外向 Claude 桌面版（Opus 5.5）詢問產生的。提問：「作業用的多元線性回歸（Multiple Linear Regression）完整分析，要將相關結果與模型放上網頁，我打算用 Flowbite＋日式風格，要有日夜間模式，請給我 prompt」）
>
> 任務
>
> 請幫我建立一個「多元線性回歸（Multiple Linear Regression）分析儀表板」網頁，作為研究所作業，最後要部署到 GitHub Pages。
>
> 技術規格
>
> - 純前端靜態網站：HTML + Tailwind CSS + Flowbite（用 CDN 引入）
> - 圖表：ApexCharts（Flowbite 官方搭配的圖表庫）
> - CSV 解析：PapaParse
> - 回歸計算：在瀏覽器端用 JavaScript 實作最小平方法（正規方程式 β =

$(X^TX)^{-1}X^Ty$），不需要後端
- 不使用任何需要建置工具的框架，打開 index.html 就能執行

版面結構

- 左側固定側邊欄（Flowbite Sidebar），手機版可收合
- 側邊欄頁面切換：
  1. 資料總覽
  2. 模型結果
  3. 預測
- 頂部導覽列：網站標題、日／夜間模式切換按鈕
- 頁面切換採用單頁應用方式（隱藏／顯示區塊），不重新載入

功能需求

基本功能

- CSV 上傳：使用 Flowbite 的拖曳上傳區塊（Dropzone）
- 上傳後可選擇目標變數（y）與特徵變數（X，多選）
- 類別欄位自動做 One-hot Encoding，並刪除第一個類別以避開虛擬變數陷阱

加分功能 1：下拉選單切換兩種 problem

- 側邊欄頂部放 Flowbite Dropdown，可切換：
  - Problem 1：【填入問題描述、預設資料集、目標變數】
  - Problem 2：【填入問題描述、預設資料集、目標變數】
- 切換時自動載入對應的資料集和預設設定

加分功能 2：可輸入任意資料集網址

- 提供文字輸入框，可貼上 CSV 網址並載入
- 預設值：https://raw.githubusercontent.com/Avik-Jain/100-Days-Of-ML-Code/master/datasets/50_Startups.csv
- 讀取失敗時，用 Flowbite Alert 顯示錯誤訊息

各頁面內容

資料總覽

- KPI 卡片：資料筆數、欄位數、缺失值數量
- 資料表格（Flowbite Table，可捲動）
- 敘述統計表（平均數、標準差、最小值、最大值）
- 相關係數熱力圖

模型結果

- KPI 卡片：R^2、Adjusted R^2、RMSE、截距
- 迴歸係數表：係數、標準誤、t 值、p 值
- 係數長條圖
- 殘差圖（預測值 vs 殘差）
- 實際值 vs 預測值散佈圖

預測

- 依特徵自動產生輸入欄位（預設填入平均值）
- 即時顯示預測結果

> 日式設計風格
>
> - 整體感覺：大量留白、低彩度、細線條、安靜沉穩，參考日本設計的「間」
> - 字型：Google Fonts 的 Noto Sans JP（內文）、Noto Serif JP（標題）；中文顯示正常
> - 圓角小（rounded-md 以下），陰影極淡或不用，改用 1px 細邊框區隔
> - 卡片之間間距寬鬆
>
> 日間模式配色
>
> - 背景：生成り色 #FAF8F5
> - 卡片：#FFFFFF，邊框 #E8E4DE
> - 主色：藍鼠 #7B90A6
> - 輔助色：抹茶 #8A9A5B、櫻色 #E8C4C4
> - 文字：墨色 #2B2B2B
>
> 夜間模式配色
>
> - 背景：濡羽色 #1C1F24
> - 卡片：#252930，邊框 #353A42
> - 主色：淺藍鼠 #9FB1C4
> - 輔助色：淡抹茶 #A8B87A、淡櫻 #D9A9A9
> - 文字：生成り #EAE6DF
>
> 日／夜間模式規格
>
> - 使用 Tailwind 的 class 策略（darkMode: 'class'）
> - 第一次開啟時依照系統偏好（prefers-color-scheme）
> - 使用者切換後存到 localStorage，下次開啟時保留
> - 切換按鈕用太陽／月亮圖示
> - ApexCharts 圖表也要跟著切換主題色
>
> 其他要求
>
> - 響應式設計，手機和桌機都能正常瀏覽
> - 介面文字使用繁體中文
> - 程式碼加上中文註解
> - 檔案結構：index.html、css/style.css、js/app.js、js/regression.js
> - 完成後附上部署到 GitHub Pages 的步驟
>
> 請先評估這份規格

Claude

我拿這份規格和現在的網頁逐項比對過了。結論是：介面和視覺可以照規格改，但它的運算部分少了作業的必要項目，不能照抄，運算要保留現在已經驗證過的版本。

一、規格缺了作業要求的項目

作業要求	規格	現有網頁
特徵選擇（必做）	只有手動多選 X，沒有選擇方法	Forward、RFE、SelectKBest，加上 k 值曲線
模型評估	沒有切分訓練／測試集，R^2 是用訓練資料自己算的，會高估	80/20 切分，加上 5-fold CV

預測圖加信賴區間或預測區間（必做）	完全沒有	預測圖帶 CI 和 PI 色帶，另外算 PI 覆蓋率
回歸假設檢查	沒有	DW、BP、JB、VIF 和殘差圖

如果照規格做，網頁會少掉作業明確寫的兩個必做項目。

二、規格的技術問題

1. 直接算 $(X^TX)^{-1}$ 數值不穩：50_Startups 的數值在 10^5 等級，X^TX 會到 10^{12} 以上，容易算出錯誤結果。現有核心先標準化再算，已經和 statsmodels 比對過，誤差在 1e-12 以下。
2. p 值要用 t 分佈：規格沒說怎麼算。現有核心已經實作並驗證。
3. 缺失值和不能用的欄位：規格沒提到。Student 資料有 235 格缺失；日期、ID 欄如果被當成類別做 one-hot，會產生幾百個欄位。現有核心會補值並自動排除這些欄位。
4. Noto Sans JP 顯示中文：同一個漢字，日文字型的字形和繁中不同，例如「直」「骨」「誤」，台灣讀者看會覺得怪。建議改用 Noto Sans TC 和 Noto Serif TC，一樣有日式的安靜感，字形正確。
5. Tailwind Play CDN：官方標註不適合正式環境，主控台會出現警告。作業用沒問題，知道就好。
6. Problem 1／2 的【填入…】：直接填 Flood 和 Student 即可。

三、規格比現有網頁多的部分

- 側邊欄單頁切換：版面更像儀表板。
- 相關係數熱力圖、敘述統計表、係數長條圖：現有網頁沒有，是真的加分。
- 日式配色和字型：視覺更有特色，對應「結果美觀」那 15%。
- 拖曳上傳、手動選 X、預設值用平均數：都是小功能。

四、建議做法

保留 stats.js、mlr.js 當運算核心，前端照規格重寫成 Tailwind、Flowbite、ApexCharts 加日式風格。規格要求的 regression.js，就由這兩個檔案擔任。

頁面規劃依規格的三頁再加一頁，剛好對應 CRISP-DM：

頁面	內容
① 資料總覽	KPI、資料表、敘述統計、相關係數熱力圖、欄位用途
② 模型結果	手動選 X 當候選範圍，在範圍內自動做特徵選擇；KPI、係數表、係數長條圖、k 值曲線
③ 評估	預測圖加 CI/PI、實際值對預測值、殘差圖、五大假設檢查
④ 預測	依特徵自動產生表單，預設平均數，即時顯示預測值和區間

ApexCharts 的 rangeArea 圖可以畫 CI/PI 色帶，heatmap 可以畫相關係數，功能都夠用。

要提醒的是：加分項（下拉切換、輸入網址）現在的網頁已經做到了。這次重寫主要是提升視覺和多加三張圖，大約是重做整個介面的工作量。運算核心不動，所以先前和 statsmodels 的比對結果仍然有效。

要照這個做法進行嗎？還有兩點想確認：
1. 字型同意改用 Noto Sans TC 和 Noto Serif TC 嗎？
2. 手動選 X 用「候選範圍內自動選擇」可以嗎？另一種做法是加一個「不做選擇，全部使用」的開關。

使用者

> 主要是美觀、套版跟排版

Claude

了解，這次的重點是套用規格的版型和視覺，功能維持現有、已經驗證過的版本。

做法：
- 版型照規格：Tailwind、Flowbite、ApexCharts、左側側邊欄單頁切換、日式配色、日夜模式。
- 補上規格裡現有網頁沒有的部分：敘述統計、相關係數熱力圖、係數長條圖、拖曳上傳、手動選 X、預測頁預設填平均數。
- 運算核心沿用。
- 字型照我的建議改用 Noto Sans TC 和 Noto Serif TC，視覺一樣，繁中字形才正確。
- 手動選 X 當作「候選範圍」，方法選單另外加一個「不篩選，全部使用」。

先對運算核心做三個小改動，讓它支援新版面：限定候選特徵、預測頁預設填平均數、長條圖用的標準化係數。

Claude

運算核心改好，和 statsmodels 的比對仍然全部通過。接著照規格重寫版面，先寫 index.html：

Claude

接著寫 css/style.css，放日式配色的色票和共用元件樣式：

Claude

接著重寫 js/app.js，負責頁面切換、Flowbite 元件、ApexCharts 圖表和日夜模式，註解用中文：

Claude

三個檔案都寫好了。用 Edge headless 逐頁截圖檢查，先看日間模式的題目 B 四個頁面：

Claude

模型頁的係數長條圖超出卡片、壓到右邊特徵選擇圖，我猜是 Tailwind CDN 還沒套用兩欄版面前圖表就抓到錯誤寬度。我接著用瀏覽器實際量測來確認這個猜測。

Claude

Chrome 截圖已恢復正常，兩張圖寬度都正確（466px），確認先前的溢出只是 headless 截圖時機差造成的；我仍會加上頁面載入後重畫圖表的機制，並修正係數圖左側標籤被切掉的問題。接著檢查評估頁。

Claude

發現預測圖兩個問題：y軸被固定從0開始導致區間色帶壓扁、信賴區間與預測區間透明度沒生效導致色帶重疊、預測線被蓋住。接下來我會自己計算y軸範圍，並改用帶透明度的rgba色值來修正。

Claude

修正後色帶正確顯示了。剩下座標軸的刻度是 82.26、56.9
這類零碎數字，不好讀。加一個函式，把座標軸範圍取整到 1、2、2.5、5 的倍數：

Claude
日間模式的評估頁也正常，刻度都是整數了。接著檢查模型頁和預測頁：

Claude
模型頁與預測頁都運作正常：將 Attendance 改成 100 後，預測值即時更新為
71.2，未入選特徵也正確顯示灰色。接下來測試手機版側邊欄，以及自訂資料集中「50_S
tartups」的流程。

Claude
自訂資料集流程確認正常，50_Startups 的 R^2 為 0.9464，與之前一致。由於 Chrome
視窗無法縮小到手機寬度，我改用 390px 的 iframe
來測試手機版，包含側邊欄開合情況。

Claude
手機版沒有橫向溢出，側邊欄也正確收在畫面外。測試點開選單、切換頁面，以及切換後
側邊欄會不會自動收回：

Claude
側邊欄可以正常打開，前面量到的是動畫還沒跑完的位置。截一張打開時的畫面，再確認
切頁後會自動收回：

Claude
功能正常：切換頁面後側邊欄確實已收回（隱藏狀態、class 恢復為
-translate-x-full），先前量到 left 0 只是因為 iframe
動畫較慢、量測時間點太早所致。接下來檢查主控台是否有錯誤。

Claude
深色模式下的 Flood 顯示正常，主控台無錯誤，但殘差圖的 y 軸出現浮點誤差產生的
-1.39e-17 刻度。我會修正殘差軸讓它以 0 為中心取整，並把極小值格式化顯示為 0。

Claude
殘差圖的 y 軸刻度現在是
0.1、0.05、0、-0.05、-0.1，浮點誤差的問題修好了。關閉測試分頁：

Claude
我照規格重做了 HW2/web/
的版型和視覺，功能和運算核心都沒變。運算核心另外加了三個小功能，加完重跑和
statsmodels 的比對，仍然全部一致。網頁還在本機執行：http://127.0.0.1:8765/

照規格完成的部分

- 技術：Tailwind（darkMode: 'class'）、Flowbite、ApexCharts、PapaParse，打開
  index.html 就能用，不需要建置。
- 版面：頂部導覽列加上左側固定的 Flowbite
  側邊欄，手機版可收合。側邊欄頂部是題目下拉選單，下面是單頁切換。
- 日式風格：生成り底、白卡片、1px 細線、rounded-md、不用陰影、寬鬆間距；色票是
  藍鼠、抹茶、櫻，深色模式用濡羽色和生成り。
- 日夜模式：第一次開啟依系統偏好，切換後存在
  localStorage，按鈕用太陽和月亮圖示，ApexCharts 的配色會跟著切換。
- 新增的圖表和功能：敘述統計表、相關係數熱力圖、係數長條圖、拖曳上傳、候選特徵
  X 多選、預測頁預設填平均數、讀取失敗時用 Alert 顯示錯誤。
- 檔案結構：index.html、css/style.css、js/app.js。規格裡的
  js/regression.js，由已驗證的 js/mlr.js 和 js/stats.js 擔任。

和規格不同的地方

- 頁面是四頁，不是三頁：資料總覽、模型結果、評估、預測。多出的「評估」頁放作業必做的預測圖（含 CI/PI）和五大假設檢查，四頁剛好對應 CRISP-DM。
- 字型改用 Noto Serif TC 和 Noto Sans TC：如果用 JP 字型，部分漢字會是日文字形。
- 櫻色 #E8C4C4 在白底上太淡，資料點和負係數會看不清楚，所以另外加了深一點的「深櫻」#BE8080。

測試結果

我在真實 Chrome 裡檢查了日夜兩種模式和四個頁面，以及手機寬度 390px，沒有橫向捲動，主控台也沒有錯誤。各項功能都正常：
- 三個題目都能切換。
- 50_Startups 的 R^2 是 0.9464，和舊版一致。
- 預測值會即時更新。
- 手機版側邊欄能打開，切頁後會自動收回。

測試過程中修掉的問題：
- 預測圖的 y 軸被固定從 0 開始，色帶被壓扁。
- 信賴區間和預測區間的透明度沒有生效，兩條色帶分不出來。
- 座標軸刻度出現零碎小數，殘差圖還有浮點誤差（-1.39e-17）。
- 係數圖左側的標籤被切掉。
- 網路慢時圖表可能抓到錯誤寬度：改成頁面載入完成後再重畫一次。

部署到 GitHub Pages 的步驟

1. 在 GitHub 建立一個新的 public repo，例如 AIoT-HW2-MultipleLR。
2. 把 HW2/web/ 裡的內容（index.html、css/、js/、data/、tests/）放在 repo 的根目錄，然後推送：

```
git init
git add .
git commit -m "HW2 multiple linear regression dashboard"
git branch -M main
git remote add origin https://github.com/<帳號>/AIoT-HW2-MultipleLR.git
git push -u origin main
```

3. 到 repo 的 Settings → Pages，在 Source 選 Deploy from a branch，Branch 選 main、資料夾選 / (root)，按 Save。
4. 等大約 1 分鐘，網址會是 https://<帳號>.github.io/AIoT-HW2-MultipleLR/。
   - 直接開啟某個題目：網址後面加 ?problem=student。
   - 直接載入某份資料：加 ?url=<CSV 網址>。

要我幫你建立 repo 並推上去的話，請告訴我 repo 名稱，以及 notebook 要不要一起放。推送是公開動作，我會先列出要推的檔案給你確認。

使用者

> https://github.com/hobartXIII/HW2-Multiple-Linear-regression.git

Claude

先確認遠端 repo 的狀態，以及這台電腦的 git 和 GitHub 登入狀態：

Claude

遠端 repo 是空的，推送時可能要透過瀏覽器登入 GitHub。在推送前，我先確認整體結構（HW2 整個作為 repo，網頁由 Actions 從 web/ 發佈）、撰寫 README.md，並排除含驗證參數的 readme.html、data/ 及可重新產生的大型檔案；接下來我會先整理好要上傳的檔案並在本機 commit，暫不推送。

Claude

發現一個問題：.gitignore 裡的 data/ 規則連 web/data/
也一起排除了，網站的兩份資料沒有被加進去。改成只排除最上層的 /data/：

Claude

我在本機建好了 repo 並 commit 兩次，還沒有推送。推送後 repo
就是公開的，請你先確認下面的檔案清單。

會上傳的 15 個檔案（共約 3.3 MB）

檔案	內容
README.md	作業要求的流程與成果整理，含網站連結、資料集、CRISP-DM 摘要、結果表、重現步驟
5115056022_hw2.ipynb	主程式，保留所有輸出
outputs/lb/…publicleaderboard….csv	Kaggle 排行榜，notebook 的名次段落要讀它
web/	網站：index.html、css/、js/、data/（兩份 CSV，1.7 MB）、tests/
.github/workflows/pages.yml	把 web/ 自動發佈到 GitHub Pages
.gitignore	排除清單

不會上傳的檔案

- readme.html：裡面有 LMS 驗證參數。
- data/：約 150 MB。
- 模型檔和 submission_flood.csv。

請留意

排行榜 CSV 裡有其他 Kaggle 參賽者公開的隊名和帳號。這些在 Kaggle
上本來就是公開資料，但如果你不想轉載，我可以只保留 notebook 會用到的 Score
欄。

推送後你要做的一步

到 repo 的 Settings → Pages，把 Source 設成 GitHub
Actions。之後每次推送都會自動部署，網址是：
https://hobartxiii.github.io/HW2-Multiple-Linear-regression/

Claude

我把 repo 推上 GitHub 了，遠端 main 和本機一致，兩個 commit 都在：
https://github.com/hobartXIII/HW2-Multiple-Linear-regression

網站還沒上線，要等你開啟 Pages。這次推送已經自動觸發了部署流程，但 Pages
還沒開啟，所以第一次執行會失敗，這是預期的。

開啟 GitHub Pages

1. 打開
   https://github.com/hobartXIII/HW2-Multiple-Linear-regression/settings/pages
2. 在 Build and deployment → Source 選 GitHub Actions。
3. 到 Actions 分頁，點左邊的「Deploy web to GitHub Pages」，按右上角 Run workflow 重新部署。也可以重新執行剛才失敗的那次。
4. 大約 1 分鐘後，網站會在這裡上線：
   https://hobartxiii.github.io/HW2-Multiple-Linear-regression/

完成後告訴我，我會檢查線上版本：兩個題目、50_Startups 網址載入，以及 CDN 資源能不能正常載入。

作業還剩的部分

這些需要你自己完成，我可以幫忙整理內容：
- ChatGPT 對話：匯出成 PDF。
- NotebookLM 摘要：100 字以上，放進報告。
- 報告 PDF：CRISP-DM 流程，再加上 GPT 輔助內容、NotebookLM 摘要、主流解法比較，並標明哪些是「GPT 輔助內容」、哪些是「NotebookLM 摘要」。
- 繳交的 zip：5115056022_hw2.zip，裡面放 notebook、報告和附件，報告裡附上 GitHub 和網站連結。

使用者

> 整理作業剩下的部分

Claude

作業剩下的部分裡，報告 PDF 我可以幫你整理。另外兩項需要你自己操作：ChatGPT 對話的匯出，以及 NotebookLM 摘要。我不能替你使用 NotebookLM，也不能編造摘要內容，所以報告裡會留好位置，並附上可以直接用的 NotebookLM 資料來源清單和提問。

報告裡「網路主流解法比較」那一節需要外部資料佐證，我先查兩個題目的公開解法：

Claude

找到第 1、2 名的公開解法說明，可以當作比較的依據。接著從 notebook 匯出報告要用的圖：

Claude

圖都匯出了。再截一張網頁截圖放進報告的加分功能章節：

Claude

截圖沒問題。把圖檔改成有意義的名稱，接著寫報告：

Claude

報告初稿寫好了，我又核對了一次裡面的每個數字。接著用 Edge 轉成 PDF：

Claude

這台電腦沒有 PDF 轉圖工具，沒辦法直接看 PDF。我改成檢查頁數，再用截圖看 HTML 的實際排版：

Claude

我把報告整理好了，有 HTML 原檔和轉好的 12 頁 PDF。這台電腦沒有 PDF 轉圖工具，所以我沒辦法直接看 PDF，只能確認頁數，再用 HTML 截圖檢查排版。截圖上的版面和圖表都正常，PDF 請你自己開來看一遍。

- HW2/report/5115056022_hw2_report.pdf
- HW2/report/report.html：修改用的原檔，改完我可以重新轉 PDF。

- HW2/report/figures/：從 notebook 匯出的 10 張圖，加上 2 張網頁截圖。

報告內容與評分項目的對應

章節	內容	對應評分
封面	學號、GitHub、網頁連結、Kaggle 成績	—
一、研究脈絡與資料集來源	兩個資料集的來源連結、篩選過程（為什麼不用 flood.csv）	資料集來源與研究脈絡（10%）
二、三、CRISP-DM	兩題各六個步驟，含圖表、指標、假設檢查、係數解讀	CRISP-DM（25%）
二之 Kaggle 小節	Public 0.84458 / Private 0.84426、約第 1,850 / 2,794 名、排行榜分佈圖	Kaggle 名次與預測評估（10%）
四、主流解法比較	S4E5 第 1、2 名的解法和討論區的「特徵總和」分析；Student 對照一篇期刊論文（R^2 0.660）和一份 CMU 課程專題	網路主流解法比較
五、加分網頁	兩個加分功能、和 statsmodels 的比對驗證、截圖	加分
六、七	NotebookLM 摘要、GPT 輔助內容	15%
八、結論與參考資料	—	—

需要你補的地方

1. 第六節 NotebookLM 摘要：我留了位置，也附上 5 個建議的資料來源和一段可以直接用的提問。請在 NotebookLM 產生摘要後貼進去，摘要要 100 字以上。
2. 第七節 GPT 輔助內容：這次的程式和分析實際上是用 Claude Code 完成的。我照實寫出了 AI 協助的部分和你自己的決策，標題暫時用作業要求的「GPT 輔助內容」。請你決定標題和說明要怎麼寫，例如如果你另外有和 ChatGPT 的對話，要附上哪一份。
3. AI 對話紀錄 PDF：請你匯出後一起放進 zip。

把 NotebookLM 摘要和第七節的決定給我，我就幫你補進報告、重新轉 PDF。接著再把 5115056022_hw2.zip 打包好，內容是 notebook、報告 PDF 和對話紀錄。

另外，report/ 資料夾目前沒有加進 git，也還沒推上 GitHub；要不要上傳由你決定。

Sources:
- S4E5 1st place solution (https://www.kaggle.com/competitions/playground-series-s4e5/writeups/aldparis-1st-place-solution)
- S4E5 2nd place solution (Peaky Blenders) (https://www.kaggle.com/competitions/playground-series-s4e5/writeups/peaky-blenders-2nd-place-solution-team-peaky-blend)
- S4E5 4th place solution (https://www.kaggle.com/competitions/playground-seri

es-s4e5/writeups/4th-place-solution-hill-climbing-through-the-noise)
- S4E5 discussion 499274 (https://www.kaggle.com/competitions/playground-series-s4e5/discussion/499274)
- IJNMT 論文 (https://ejournals.umn.ac.id/index.php/IJNMT/article/view/4762)
- CMU capstone (https://www.stat.cmu.edu/capstoneresearch/fall2024/315files_f24/team5.html)

使用者

> 「相關係數熱力圖：數值欄位（目標與相關最高的 15 個）」
> 圖內沒有顯示數據，只有滑鼠移上去才有，應該要想辦法正常顯示，而不是隱藏。
> 另外，可以上傳的功能應該要整合至「自訂資料集」區塊，且自訂資料集要有資料後才會顯示相關欄位與數據。

Claude

原因是我設定欄位超過 12 個就隱藏格子裡的數字，Flood 有 16 欄所以沒顯示。改成依照實際格子寬度決定：寬度夠就顯示（取到小數第 2 位，欄位多時字小一點），只有手機這種格子太窄的情況才隱藏。

Claude

熱力圖的 16×16 格現在都會顯示數值了（共 256 個）。另外看到格子裡出現 -0.00，這是 -0.004 這類值四捨五入的結果，順手改成顯示 0.00：

Claude

熱力圖修好了，本機頁面我也重新載入確認過：
- Flood 的 16×16 格（目標加上相關最高的 15 個欄位）每格都直接顯示相關係數，取到小數第 2 位。
- 不會再出現 -0.00。
- 手機上格子太窄時，數字仍然只在滑鼠提示裡顯示，避免擠在一起。

Claude

不過手機上數值仍然被隱藏，不符合「不要隱藏」的要求。改法：熱力圖的每格保留至少 36px 的寬度，數值一律顯示；螢幕不夠寬時，熱力圖可以在卡片裡左右滑動，就像資料表那樣。

Claude

手機版已經正常，每格數值清晰可見且頁面沒有橫向溢出，但卡片右側因圖表高度超出容器而多出一條垂直捲軸。接下來我會把垂直方向的捲動關閉。

Claude

桌面版題目 B 的熱力圖正常，7×7 共 49 格都有數值，也沒有多出捲軸。不過手機版還有 12px 的內容被裁掉，要確認被裁的是不是 x 軸標籤：

Claude

確認被裁掉的 12px 只是 ApexCharts 底部的空白，x 軸標籤（709px）沒被切到容器底部（721px），所以關閉垂直捲動是安全的。接下來我會清掉測試檔並在本機 commit。

Claude

改好了，熱力圖現在不論螢幕寬窄都會在格子裡顯示數值，不再隱藏：
- 桌面：圖表跟卡片一樣寬，所有格子都有數值。我測了 Flood 的 16×16（256 格）和 Student 的 7×7（49 格）。
- 手機：每格保留至少 36px，數值一樣顯示。超出螢幕的部分可以在卡片裡左右滑動，和資料表的操作相同，頁面本身不會橫向溢出。我在 390px 寬度下確認 256 格都有顯示。
- -0.00 一律顯示成 0.00。

Claude

接著處理上傳：上傳和網址輸入應該是「自訂資料集」專屬的功能。改成這樣：

- 選題目 A 或 B：不顯示上傳區塊，直接載入預設資料。
- 選自訂資料集：清空目前的資料，只顯示「自訂資料集」區塊（拖曳上傳加上網址輸入，網址欄預先填好 50_Startups 範例）。載入資料後，才出現 KPI、變數設定、資料表、統計和熱力圖。
- 模型、評估、預測三頁：還沒有資料或模型時，顯示提示文字「請先在資料總覽載入資料」，不顯示空的表格和圖表。

先改 index.html：

Claude

接著改 app.js 的流程：

Claude

renderVisibleCharts 原本要求必須有模型才畫圖，但總覽頁的熱力圖只需要資料。這裡要分開判斷，另外把上傳、網址和啟動流程也改成新的寫法：

Claude

還有個時序問題：題目A資料還在讀取時若切到「自訂資料集」，等A讀完仍會把舊資料塞回畫面。我會加入讀取序號，只採用最新一次的讀取結果來修正這個問題。

Claude

用瀏覽器把整個流程走一遍：

Claude

四個步驟都符合預期。再截一張自訂資料集的空白狀態，以及讀取時序問題的畫面：

Claude

改好了，上傳和輸入網址現在只在「自訂資料集」裡出現，資料載入後才會顯示欄位和分析結果。我在瀏覽器裡把下面每一步都走過，主控台沒有錯誤：

操作	結果
選題目 A 或 B	不顯示上傳區塊，直接顯示該題目的資料和分析
選「自訂資料集」	清空畫面，只剩「自訂資料集」區塊：拖曳上傳加網址輸入，網址欄預填 50_Startups。KPI、變數設定、表格、熱力圖都隱藏
自訂資料集還沒載入時，切到模型、評估、預測頁	顯示提示「尚未建立模型：請先在資料總覽載入資料…」，不出現空表格
按「載入網址」或上傳檔案	才出現資料總覽的所有內容，其他三頁也有結果（50_Startups 的 R^2 0.9464）
從自訂切回題目 B	上傳區塊隱藏，載入題目 B
題目 A 還在讀取時就切到自訂	A 讀完的結果會被忽略，不會把資料塞回畫面

另外兩個小調整：

- 網址帶 ?problem=custom 時，開啟就是空白的自訂狀態；帶 ?url=... 時，直接載入那份資料。
- 如果模型建立失敗，例如把候選特徵全部取消，資料總覽照常顯示，其他三頁改顯示提示。

目前本機比 GitHub 多 3 個 commit：熱力圖兩次、這次一次。要推送嗎？

使用者

> 如果模型建立失敗，例如把候選特徵全部取消，資料總覽照常顯示，其他三頁改顯示提示，是這樣嗎？

Claude

這句話說的是「資料有了，但模型建不起來」的情況。我剛才沒有實際測這個情境，先測一次再說明：

Claude

我在題目 B 實際測過了，行為和那句話描述的一致。

這句話指的情境：資料已經載入，但模型建不起來。最常見的就是在「變數設定」把候選特徵 X 全部取消，沒有特徵就沒辦法做回歸。另外兩種是：可用的資料少於 20 筆，或選出的特徵完全共線。

這時的畫面：

位置	顯示內容
頁面頂端	錯誤提示：「請至少選擇一個候選特徵。」
資料總覽	照常顯示：KPI、特徵勾選清單、資料表、敘述統計、熱力圖都在，你可以直接重新勾選特徵
模型結果、評估、預測	不顯示舊的或空的圖表，改成提示「尚未建立模型：請先在資料總覽載入資料，並選擇目標變數與至少一個特徵」

恢復的方式：重新勾選任何一個特徵（我測試勾了 Attendance），模型會自動重建，錯誤提示消失，三個頁面恢復顯示結果。只用 Attendance 時 R^2 是 0.35。

設計成這樣的原因：資料總覽是修正設定的地方，如果失敗時連它一起隱藏，就沒有地方可以把特徵勾回來。

使用者

> 調整內容頁面盡量滿版

Claude

主內容區目前限制最大寬度 72rem（max-w-6xl），在寬螢幕上兩側會留很多空白。改成填滿側邊欄右邊的全部寬度，只保留內距：

- 預測頁的輸入欄位，螢幕越寬欄數越多：最多 4 欄。
- 頁首的說明文字保留最大寬度，避免一行太長不好讀。
- 熱力圖原本只在繪製時量一次寬度，所以補上「調整視窗大小時重畫」，滿版之後才能跟著寬度變化。

Claude

內容寬度從原本最多約 1150px，變成填滿側邊欄右側的 1617px，熱力圖也跟著變成 1463px 寬。Chrome 截圖又逾時了，改用 Edge 在 1920 寬度截圖看整體效果：

Claude

內容頁面改成滿版了。在 1920 寬的螢幕上，主內容從原本最多約 1150px 變成約 1620px，填滿側邊欄右側的空間，左右各保留 48px 內距。

- KPI、變數設定、資料表、熱力圖、圖表：全部撐滿寬度，資料表一次能看到更多欄。
- 預測頁：輸入欄位依螢幕寬度增加欄數，最多 4 欄，1920 寬時是 4 欄。右側的預測結果卡維持固定寬度。
- 頁首說明文字：仍然保留最大寬度，避免一行太長不好讀。要連這部分也拉滿的話告訴我。
- 熱力圖：補上調整視窗大小時自動重畫，滿版後會跟著視窗寬度變化。

本機已經 commit，要推送更新線上網站嗎？

使用者

> 目前這樣就可以，再重新依作業需求確認與整理一次

Claude

我依照作業說明（以「二、作業內容」和評分標準為準，加上補充的加分項）逐項核對一遍。先確認各個交付物的實際狀態：

Claude

我逐項核對了作業要求，程式、網頁和評分要的分析內容都已經完成。目前還沒完成的，是兩項需要你自己操作的 AI 相關內容，以及最後的打包。

二、作業內容

要求	狀態	位置／說明
Kaggle 資料集，10–20 個特徵，標明來源和連結	✅	A：Flood S4E5，20 個特徵；B：Student Performance，19 個特徵。來源連結寫在 notebook 開頭、報告第一節、README
線性回歸預測	✅	OLS，另外比較 Ridge 和 Lasso
特徵選擇（必做）	✅	5 種方法加上 k 值曲線，都只用訓練資料
模型評估（必做）	✅	MAE、MSE、RMSE、R^2、Adj R^2、5-fold CV、五大假設檢查
預測圖加信賴區間或預測區間（必做）	✅	notebook、報告、網頁都有 95% CI 和 PI，並算出實際覆蓋率
CRISP-DM 六個階段	✅	notebook 和報告的兩個題目都完整寫了六步
ChatGPT 對話匯出成 PDF	⏳ 你	請匯出後放進 zip
NotebookLM 摘要（100 字以上）	⏳ 你	報告第六節留了位置，附上 5 個建議來源和提問
標明「GPT 輔助內容」和「NotebookLM 摘要」	⚠️ 待你決定	兩個標籤都放好了；第七節的標題和說明，請依你實際用的工具決定
主程式 學號_hw2.ipynb	✅	5115056022_hw2.ipynb，33 個程式格全部執行過，0 個錯誤，11 張圖

報告 PDF	✅ 初稿	report/5115056022_hw2_report.pdf，12 頁，補完上面兩項後要重新轉
網路主流或更好解法的比較	✅	報告第四節：S4E5 第 1、2 名的解法與討論區分析；Student 對照一篇期刊論文和一份 CMU 課程專題
打包成學號命名的 zip	⏳	補完後打包 5115056022_hw2.zip
（選做）GitHub 連結和 README.md	✅	repo 和 README 已上線，網站回應正常

三、評分標準

項目	比重	狀態
CRISP-DM 流程完整、邏輯清楚	25%	✅
GPT 對話與 NotebookLM 摘要	15%	⏳ 目前唯一還沒完成的評分項目
資料集來源與研究脈絡	10%	✅ 包括資料集的篩選過程（為什麼不用 flood.csv）
模型能執行，有特徵選擇和評估	25%	✅ 網頁運算和 statsmodels 比對，誤差小於 1e-12
結果合理、美觀、有說服力	15%	✅ 每個結論都對照過實際輸出
Kaggle 名次和預測結果評估	10%	✅ Public 0.84458，約第 1,850 / 2,794 名，另有預測圖和指標

補充的加分項

加分項	狀態
下拉選單呈現兩種 problem（+1）	✅ 側邊欄可以切換題目 A 和 B
可以輸入任意資料集（+2）	✅ 「自訂資料集」可以輸入網址或上傳檔案，50_Startups 範例測試正常

兩個要注意的地方

1. 補充說明寫「do two problems but choose one of the topic to upload」：我們把兩題都放在同一份 notebook 和報告裡，內容比要求多，應該沒有問題。如果你理解成「只能上傳一題」，我可以把報告精簡成只寫一題，兩題都做的部分改由網頁呈現。
2. 報告裡的網頁截圖，是「自訂資料集」流程和滿版改版之前截的。最後轉 PDF 時，我會重新截圖。

最後的 zip 打算這樣放

```
5115056022_hw2.zip
├── 5115056022_hw2.ipynb
├── 5115056022_hw2_report.pdf
├── AI 對話紀錄.pdf            ← 你匯出
├── outputs/lb/…leaderboard.csv  （notebook 的 Kaggle 名次段落要讀它）
└── web/                         （網頁原始碼，1.8 MB）
```

接下來只要你提供 NotebookLM 摘要、第七節的標題決定和對話紀錄 PDF，我就重新截圖、轉 PDF，打包 zip。

使用者

> 請使用 NotebookLM 對網路上同主題的解法進行研究，並撰寫一份 100 字以上的摘要，放入報告中。

Claude

NotebookLM 要讀得到來源內容才能摘要。Kaggle 解法頁由 JavaScript 載入、部分要登入，NotebookLM 只抓得到外框，所以我改找 GitHub 專案和 PDF 全文。學生成績的期刊論文全文已經下載下來，共 6 頁，這份論文用的正是同一份資料（6,607 筆，目標是 Exam_Score）：

```
D:\AIoTAI\HW2\report\notebooklm_sources\IJNMT_student_performance_MLR.pdf
```

CMU 那個網頁抓回來是空白的，NotebookLM 一樣讀不到，所以不用加。

請在 NotebookLM 這樣做

1. 來源：在筆記本加入下面這些來源。

題目	來源	加入方式
洪水	https://github.com/nhamhung/flood-prediction	網站
洪水	https://github.com/surajwate/S4E5-Flood-Prediction-Dataset	網站
洪水	Kaggle 第 1、2 名解法（登入後複製內文）	複製的文字
學生成績	上面那份 PDF	上傳檔案

2. 提問：要求「只整理來源裡有的內容」，避免 NotebookLM 推測：

> 請只根據來源內容，撰寫一份 200 字以上的繁體中文研究摘要，分兩段：第一段整理洪水機率預測（Kaggle Playground S4E5）的主流解法，包括特徵工程、使用的模型與融合方式、達到的 R^2；第二段整理學生成績資料（Student Performance Factors）的多元線性回歸研究，包括使用的變數、顯著因素、R^2 與結論。來源沒有提到的內容請不要推測。

3. 把結果貼給我。

我會把摘要放進報告第六節，再重新轉 PDF。

Sources:
- nhamhung/flood-prediction (https://github.com/nhamhung/flood-prediction)
- surajwate/S4E5-Flood-Prediction-Dataset (https://github.com/surajwate/S4E5-Flood-Prediction-Dataset)
- IJNMT 論文 PDF (https://ejournals.umn.ac.id/index.php/IJNMT/article/download/4762/1941/22824)

使用者

> NotebookLM 產生的摘要：
> 在洪水機率預測（Kaggle Playground S4E5）競賽中，未進行複雜特徵工程前的單一基礎模型（如 CatBoost、XGBoost、LightGBM 等）R^2 表現約在 0.766 至 0.846 之間[1][2]。頂尖參賽者透過特徵工程將最佳單一模型的 R^2 提升至約 0.86933[3]。關鍵的特徵工程手法包括計算每筆資料列的特徵總和（sum）、標準差（std）、最大值（max）、沿特徵軸排序（sorted features）、高於特定門檻值的特徵計數（count features），以及對特徵總和進行目標編碼（target encoder）與目標轉換[4]。主要採用的模型包含 CatBoost、XGBoost、LightGBM、PyBoost 等多種梯度提升樹（GBM）與 AutoGluon 自動機器學習工具[5][6]。最後透過嶺回歸（Ridge Regression）或線性回歸（Linear Regression）對折外預測（OOF）進行加權融合與前向特徵選擇，最終將整體 R^2 成功提升至 0.86943[3]。
>
> 在學生成績資料（Student Performance Factors）的多元線性回歸研究中，研究者基於 6,607 筆觀察值分析影響學生考試成績（Exam Score）的決定因素[9][10]。模型涵蓋 6 個自變數，包括學術因素（週學習時數、出席率、先前成績、家教輔導次數）與家庭及學習環境因素（家長參與度、學習資源取得管道）[9][11]。分析顯示該回歸模型整體達到統計顯著（F = 1601, p < 0.001），判定係數 R^2 為 0.660，即模型可解釋 66.0% 的考試成績變異[9][10]。局部檢定顯示所有 6 個變數對成績均有顯著影響（p < 0.001），其中家教輔導次數（係數 0.504）、學習時數與出席率對成績有顯著正面拉升作用，而低家長參與度與低資源取得則顯著負向影響成績[10][12]。研究結論指出，學生學術成就屬於多維度表現，除個人學習努力外，家庭支持與學習環境資源亦為極其關鍵的影響因子[9][13]。

Claude

摘要兩個題目都有涵蓋，內容具體，也遠超過 100 字，符合作業要求。其中有一點正好可以拿來和本作業對照：論文裡輔導次數的係數是 0.504，我們的模型是 0.511，非常接近。

我把這份摘要放進報告第六節，同時更新來源清單、提問，以及「與本作業的對照」那一段：

Claude

我注意到第四節和第六節有矛盾：第四節誤以為論文沒納入「家長參與、資源取得」，但 NotebookLM 摘要顯示論文其實已包含這些變數，真正多出的是家庭收入、同儕、動機、師資。我會修正第四節，讓說法與第六節一致。

Claude

NotebookLM 摘要已經放進報告第六節，PDF 也重新轉好了：HW2/report/5115056022_hw2_report.pdf，13 頁。

第六節的內容

- NotebookLM 摘要原文：兩段，洪水題目和學生成績題目各一段，保留 NotebookLM 的來源引註。
- 來源清單和提問：照你實際使用的列出。

- 「與本作業的對照」表，重點有三個：
  - 洪水題目：沒做特徵工程的 GBM 模型 R^2 是 0.766–0.846，我們的 OLS 是 0.845，代表線性回歸已經達到這個水準。
  - 學生成績：論文用 6 個變數，R^2 是 0.660；我們多納入了家庭收入、同儕等類別因素，R^2 是 0.764–0.770。
  - 輔導次數的係數：論文 0.504，我們 0.511，結論互相印證。

另外修正了第四節的一處前後矛盾：原本說我們多納入了「資源取得、家長參與」，但摘要指出論文已經包含這兩項，所以改成真正多出來的那幾個因素。

最後一步：匯出對話紀錄

1. 在 Claude Code 輸入 /export，存成檔案，建議存到 D:\AIoTAI\HW2\report\。
2. 告訴我檔名。

我會把它轉成 PDF，然後打包 5115056022_hw2.zip，內容是 notebook、報告 PDF、對話紀錄 PDF、排行榜 CSV 和網頁原始碼。

使用者

> 「NotebookLM 研究摘要」與「網路上主流或更優解法之比較與說明」要彼此分段與獨立

Claude

了解，「NotebookLM 研究摘要」和「網路上主流或更優解法之比較與說明」要各自成為獨立的章節，內容不互相引用。目前第六節的 NotebookLM 摘要後面接了一張比較表，第四節的比較裡也寫了「見第六節」，兩者確實混在一起。

調整方式：
- 兩節的標題直接用作業的原文。
- 章節順序照作業列的報告內容排：CRISP-DM → GPT 對話 → NotebookLM 研究摘要 → 主流解法比較。
- NotebookLM 那節只放摘要、來源和提問。原本跟在摘要後面的比較表，移到主流解法比較那節。

先確認目前各章節的位置：

Claude

章節順序已調整完成，但發現題目 A 的 Deployment 中提到的「互動網頁（第五節）」需要更新為第四節。接下來我會修正這處交叉引用，並檢查各節的開頭與結尾是否有切錯的地方。

Claude

結構正確。再確認比較章節裡沒有殘留「NotebookLM」的字樣，然後重新轉 PDF：

Claude

我把兩節拆開了，各自獨立，標題直接用作業的原文。PDF 也重新轉好了：HW2/report/5115056022_hw2_report.pdf。

調整後的章節順序

依照作業列的報告內容排：
1. 研究脈絡與資料集來源
2. CRISP-DM 分析流程：題目 A 洪水機率
3. CRISP-DM 分析流程：題目 B 學生考試成績
4. 加分功能：互動式網頁
5. GPT 輔助內容（使用 Claude Code）
6. NotebookLM 研究摘要

7. 網路上主流或更優解法之比較與說明
8. 結論，最後是參考資料

兩節的內容

- 六、NotebookLM 研究摘要：只放 NotebookLM
  產生的摘要原文、來源清單和提問，沒有其他內容。
- 七、網路上主流或更優解法之比較與說明：兩個題目的比較表和說明，加上原本放在第六節的「本作業與網路解法的對照」表。這一節已經沒有任何引用 NotebookLM 的文字，也拿掉了原本的「見第六節」。

另外，網頁從第五節移到第四節，題目 A 的 Deployment 裡寫的「互動網頁（第五節）」已經改成第四節。

接下來只剩對話紀錄了。請輸入 /export 存檔並告訴我檔名，我會轉成 PDF，然後打包 5115056022_hw2.zip。